

Machine Learning

Université de Tours

Fondements de l'apprentissage statistique

Clément Moreau – clement.moreau@univ-tours.fr

*
* *

Table des matières

1 Apprentissage supervisé	3
1.1 Algorithme d'apprentissage	3
1.2 Fonction de risque	3
1.3 Apprentissage linéaire	4
1.3.1 Cadre de la régression	4
1.3.2 Cadre de la classification	5
1.4 Changement de représentation	5
2 Dilemme Biais / Variance	6
2.1 Majoration du risque de généralisation	6
2.2 PAC : Probably Approximately Correct	8
2.3 Étude de 1-NN	10
2.4 Décroissance de l'erreur de généralisation	10
2.5 Erreur d'approximation	11
3 Malédiction de la dimensionnalité	12
3.1 Notions sur la régularité de fonction	12
3.2 Approximation d'une fonction lipschitzienne par 1-NN	13
4 Classificateur linéaire, Régularisation et Noyaux	15
4.1 Optimisation et contrôle du sur-apprentissage	16
4.1.1 Instabilité du paramètre w	16
4.1.2 Régularisation	19
4.2 Kernel Trick	20
4.3 Classification à noyaux et SVM	23
4.3.1 Critère de la marge	23
4.3.2 Pénalisation : Soft SVM	24
4.3.3 Convexification du risque	25
4.4 Conditions de point selle	26
5 Apprentissage statistique	27
5.1 Point de vue bayésien	28
5.2 Le programme de Fisher	28
5.2.1 La loi des grands nombres : convergence	30
5.2.2 Consistance : l'estimation de paramètres	31
5.2.3 Maximum de vraisemblance	32
5.2.4 Information de Fisher	34
5.3 Étude de la régression logistique	36
6 Synthèse sur la complexité des algorithmes	38

1 Apprentissage supervisé

1.1 Algorithme d'apprentissage

Dans la suite du document, on note $y \in \Sigma$ (où Σ est continu en régression et discret en classification) la réponse, ou *label*, à une question posée sur $x = (v_1, \dots, v_d) \in \mathbb{R}^d$.

Définition 1 (Jeu de données). *Un jeu de données dans le cadre supervisé est un ensemble $\mathcal{D} = \{(x_i, y_i) | x_i \in \mathbb{R}^d, y_i \in \Sigma\}_{i \leq n}$.*

Ces données sont des réalisations de n couples aléatoires d'échantillons indépendants et identiquement distribués (i.e. i.i.d) des données de lois (X, Y) . On notera (x, y) une réalisation particulière des données.

Définition 2 (Algorithme apprentissage). *On suppose qu'un label y unique est associé à x . Dans ce cas, on peut modéliser $y = f(x) + \epsilon$, où ϵ est un bruit aléatoire de moyenne nulle et de variance σ^2 et $f : \mathbb{R}^d \rightarrow \Sigma$, une certaine fonction.*

Un algorithme d'apprentissage calcule

$$\tilde{y} = \tilde{f}(x) \quad (1)$$

où $\tilde{f}$ est une fonction sélectionnée parmi une classe $\mathcal{H}$ de fonctions possibles.

Un tel algorithme inclue des paramètres internes qui sont optimisés sur une fonction de risque grâce à un jeu de données d'entraînement de façon à ce que la prédiction soit bonne sur ces exemples : $\tilde{y}_i \approx y_i$. La taille de la classe de fonction $|\mathcal{H}|$ est proportionnelle au nombre de paramètres à optimiser.

1.2 Fonction de risque

Un algorithme d'apprentissage supervisé est restreint à une classe de fonctions $\mathcal{H}$ que l'on choisit a priori - par exemple l'ensemble des classificateurs linéaires. L'objectif est de sélectionner $\tilde{f} \in \mathcal{H}$ avec les données d'entraînement $\mathcal{D}_{train} = \{(x_i, y_i)\}_{i \leq n_{train}}$, de façon à ce que, pour tout couple $(x, y) \in \mathcal{D}_{train}$, on ait $\tilde{y} = \tilde{f}(x) \approx y$.

Définition 3 (Fonction de risque). *Une fonction de risque (loss function) $r : \Sigma^2 \rightarrow \mathbb{R}$ est une mesure de l'erreur entre l'estimation $\tilde{y}$ et y .*

Il existe de nombreuses mesures que nous explorerons en TD/TP. Dans le cours, nous nous concentrerons sur les fonctions suivantes :

— Dans le cadre de la régression, le risque quadratique :

$$r(y, \tilde{y}) = (y - \tilde{y})^2 \quad (2)$$

— Dans le cadre de la classification, le risque 0/1 :

$$r(y, \tilde{y}) = \mathbf{1}_{\{y \neq \tilde{y}\}} = \begin{cases} 1 & \text{si } y \neq \tilde{y} \\ 0 & \text{sinon} \end{cases} \quad (3)$$

Définition 4 (Risque empirique). *L'erreur / risque empirique¹ sur les données $\mathcal{D} = \{(x_i, y_i)\}_{i \leq n}$ de la fonction $\tilde{f}$ fournie par l'algorithme est définie telle que :*

$$\tilde{R}_{\mathcal{D}}(\tilde{f}) = \frac{1}{|\mathcal{D}|} \sum_{(x_i, y_i) \in \mathcal{D}} r(y_i, \tilde{f}(x_i)) \quad (4)$$

1. Dans la suite, on omettra l'indice $\mathcal{D}$ sur lequel l'erreur est calculée. On notera simplement l'erreur empirique $\tilde{R}$ en supposant, sans perte de généralités, que $|\mathcal{D}| = n$.

Classiquement, l'ensemble de données disponible est partitionné en deux sous ensembles² appelés jeu d'entraînement (Train set) et jeu de test (Test set) tels que $\mathcal{D} = \mathcal{D}_{train} \cup \mathcal{D}_{test}$, avec $|\mathcal{D}_{train}| \approx 0.8n$.

Un phénomène caractéristique du sur-apprentissage (Overfitting) est de constater que :

$$\tilde{R}_{\mathcal{D}_{train}}(\tilde{f}) < \tilde{R}_{\mathcal{D}_{test}}(\tilde{f}) \Rightarrow \text{Overfitting} \quad (5)$$

En conséquence, un des premiers réflexes lors de l'apprentissage de modèle doit être le contrôle et l'adéquation du risque empirique sur l'ensemble de Train et de Test.

Définition 5 (Risque de généralisation). L'erreur / risque de généralisation est définie en moyenne sur la distribution jointe de (X, Y) :

$$R(\tilde{f}) = \mathbb{E}_{X,Y}[r(\tilde{f}(X), Y)] \quad (6)$$

Le but est de minimiser cette erreur moyenne. De nombreux algorithmes d'apprentissage optimisent le choix de $\tilde{f}$ dans $\mathcal{H}$ en minimisant l'erreur empirique $\tilde{R}$, qui est la seule à laquelle on ait accès :

$$\tilde{f} = \operatorname{argmin}_{h \in \mathcal{H}} \{\tilde{R}(h)\} \quad (7)$$

Toutefois, on montre facilement que si les exemples d'entraînement $(x_i, y_i)_{i \leq n}$ sont en assez grand nombre et ont la même loi que (X, Y) (i.e., la base n'est pas biaisée et couvre l'ensemble des réalisations probables), alors l'erreur empirique est un estimateur non biaisé de l'erreur de généralisation :

$$\mathbb{E}[\tilde{R}(h)] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n r(y_i, h(x_i))\right] = \mathbb{E}[r(Y, h(X))] = R(h) \quad (8)$$

1.3 Apprentissage linéaire

1.3.1 Cadre de la régression

On se place ici dans le cadre où $\Sigma = \mathbb{R}$.

Le modèle linéaire pose comme hypothèse que les données peuvent être modélisées comme une combinaison linéaire telle que :

$$y = b + \sum_{k=1}^d w_k v_k + \varepsilon \quad (9)$$

où $w_{k \in [1,d]} \in \mathbb{R}$ est le poids associé à la dimension k , b un biais (*intercept*) et ε un bruit selon une variable aléatoire ξ telle que $\mathbb{E}(\xi) = 0$.

Dans ce cas, la classe $\mathcal{H}$ est la famille des classificateurs de la forme :

$$\mathcal{H} = \{\tilde{f} : \mathbb{R}^d \rightarrow \mathbb{R} \mid \tilde{f} : x \mapsto b + \langle w, x \rangle\} \quad (10)$$

Où $\langle w, x \rangle = \sum_{k=1}^d w_k x_k$ est le produit scalaire de x et w . Elle est paramétrée par $w \in \mathbb{R}^d$ et $b \in \mathbb{R}$ de sorte que $|\mathcal{H}| = N^{d+1}$ où N est le nombre de valeurs de discrétisation choisi.

L'apprentissage supervisé dans ce cas consiste à déterminer une valeur "optimale" pour les paramètres w et b au sens de la minimisation d'une *erreur* sur les n_{train} données du jeu d'entraînement.

2. Parfois un 3ème jeu de validation est ajouté afin d'éviter les contaminations lors de l'optimisation des paramètres, ou effectuer un backtesting.

1.3.2 Cadre de la classification

On suppose le cadre d'une classification binaire $\Sigma = \{-1, 1\}$.

Dans ce cas, la classe $\mathcal{H}$ est la famille des classificateurs de la forme :

$$\mathcal{H} = \{\tilde{f} : \mathbb{R}^d \rightarrow \{-1, 1\} \mid \tilde{f} : x \mapsto \text{sgn}(\langle w, x \rangle - b)\} \quad (11)$$

Ceux-ci définissent une frontière de décision entre les deux classes +1 et -1 qui est l'hyperplan $\{x \in \mathbb{R}^d \mid \langle w, x \rangle = b\}$.

Sur la figure 1, les entrées x sont représentées par des croix lorsqu'elles appartiennent à la classe 1 (i.e les réponses y associées valent 1), et par des ronds lorsque y lorsqu'elles appartiennent à la classe -1.

L'algorithme en phase d'entraînement contient donc une procédure d'optimisation des paramètres afin de minimiser une fonction de risque donnée, par exemple la 0/1 loss définie équation (3).

Dans l'exemple en figure 1a, les valeurs de w et b ne sont pas "optimales" pour les prédictions si l'on définit l'erreur à optimiser par le nombre de mauvaises classifications des données fournies (représentées par les croix et les ronds).

1.4 Changement de représentation

Nous avons décrit précédemment le fonctionnement d'un algorithme de classification linéaire dans le cadre d'un problème de classification binaire avec deux classes : 1 et -1. Il n'est pas toujours possible de bien séparer les deux classes avec une frontière plane. La figure 2 montre un exemple où cela n'est pas possible. Dans les algorithmes de classification (binaire), plutôt que d'utiliser une classe de fonctions $\mathcal{H}$ essayant d'adapter une frontière courbe directement sur les données, on va adapter les données avec un changement de variable par une fonction ϕ telle que :

$$\phi : x \in \mathbb{R}^d \mapsto \phi(x) = (\varphi_1(x), \dots, \varphi_m(x)) \in \mathbb{R}^m \quad (12)$$

menant x dans un espace d'arrivée de dimension m dans lequel on espère voir les classes linéairement séparées par un hyperplan.

On passe ainsi d'une frontière courbe dans l'espace de départ à une frontière "aplatie" entre les classes dans l'espace d'arrivée. La classe de fonctions $\mathcal{H}$ considérée par notre algorithme est donc l'ensemble des fonctions $\tilde{f}$ effectuant des prédictions de la forme




Figure 1 – Exemples de séparations linéaires




Figure 2 – Frontière courbe entre les deux classes

$$\tilde{y} = \tilde{f}(x) = \text{sgn}(\langle w, \phi(x) \rangle - b) = \text{sgn} \left(\sum_{k=1}^m w_k \varphi_k(x) - b \right) \quad (13)$$

Si on connaît le changement de variable, le classificateur est caractérisé par un hyperplan de vecteur normal w sur lequel $\phi(x)$ est projeté afin de déterminer la classe de x . Cet axe de projection est celui qui mène d'une classe à une autre classe. Chacun des $\varphi_k(x)$ correspond à un attribut servant à construire un critère discriminant entre les classes à l'aide d'une combinaison linéaire pondérée par les w_k . Les poids correspondent à la confiance que l'on accorde à chacun de ces critères et la classe prédite correspond à un vote majoritaire sur ces attributs pondérés.

La difficulté principale consiste à trouver ces critères et donc le changement de variable ϕ . Plusieurs méthodes existent :

- Construction a priori via de la connaissance métier.
- Génération de features (linéaire, polynomiale, mixte), puis sélection via diverses techniques (Corrélation avec la variable cible Y , régularisation LASSO / Ridge / Elastic Net, Recursive Feature Elimination, ...).
- Apprentissage via des réseaux de neurones profonds.

Concernant l'optimisation des paramètres w et b , celui-ci est peut être estimé par plusieurs méthodes (voir section 4.1). L'estimateur naturel est celui des moindres carrés qui peut s'écrire sous forme matricielle :

$$b, w = ({}^tX.X)^{-1} {}^tXY \quad (14)$$

où X est de taille $(n \times (d + 1))$ et Y de taille $(n \times 1)$.

Point complexité :

La multiplication matricielle ${}^tX.X$ est effectuée en $O(nd^2)$ et l'inversion de la matrice $(d + 1) \times (d + 1)$ en $O(d^3)$ par élimination de Gauss-Jordan.

En suivant la taille des matrices calculées, on arrive à une complexité spatiale en $O(d^2 + nd)$.

2 Dilemme Biais / Variance

2.1 Majoration du risque de généralisation

Une question fondamentale en apprentissage est le **contrôle du risque**. Comment le mesurer et comment majorer l'écart entre l'erreur empirique $\tilde{R}(\tilde{f})$ et l'erreur de généralisation $R(\tilde{f})$.

De fait, on va dresser des hypothèses sur les données et les conditions d'apprentissage afin d'expliciter des bornes sur l'erreur empirique et l'erreur de généralisation. Enfin, une autre question sera de s'assurer que l'erreur de généralisation $R(\tilde{f})$ est sous contrôle et idéalement faible.

On note f^* la "meilleure" approximation au sein de $\mathcal{H}$ qui minimise l'erreur de généralisation :

$$f^* = \operatorname{argmin}_{h \in \mathcal{H}} \{ \tilde{R}(h) \} \quad (15)$$

Proposition 1. L'erreur de généralisation peut être bornée telle que :

$$R(f^*) \leq R(\tilde{f}) \leq R(f^*) + 2 \max_{h \in \mathcal{H}} |R(h) - \tilde{R}(h)| \quad (16)$$

Démonstration. La première inégalité de gauche est immédiate. Pour la seconde :

$$\begin{aligned} R(\tilde{f}) &= R(\tilde{f}) - \tilde{R}(\tilde{f}) + \underbrace{\tilde{R}(\tilde{f}) - \tilde{R}(f^*)}_{\leq 0} + \tilde{R}(f^*) - R(f^*) + R(f^*) \\ &\leq R(\tilde{f}) - \tilde{R}(\tilde{f}) + \tilde{R}(f^*) - R(f^*) + R(f^*) \\ &\leq |R(\tilde{f}) - \tilde{R}(\tilde{f})| + |\tilde{R}(f^*) - R(f^*)| + R(f^*) \\ &\leq R(f^*) + |R(\tilde{f}) - \tilde{R}(\tilde{f})| + |\tilde{R}(f^*) - \tilde{R}(f^*)| \\ &\leq R(f^*) + 2 \max_{h \in \mathcal{H}} |R(h) - \tilde{R}(h)| \end{aligned}$$

□

On appelle $R(f^*)$ l'*erreur d'approximation* qui représente l'erreur de généralisation minimale au sein de la classe de fonctions $\mathcal{H}$ tandis que $\max_{h \in \mathcal{H}} |R(h) - \tilde{R}(h)|$ constitue l'*erreur maximum de fluctuation* entre le risque empirique et le risque moyen de n'importe quel prédicteur $h \in \mathcal{H}$.




Figure 3 – Illustration du dilemme biais-variance. Augmenter la complexité du modèle (i.e. taille de $\mathcal{H}$) permet de diminuer l'erreur mais mène à un potentiel sur-apprentissage (i.e. variance du modèle trop élevée).

On retrouve dans cette inégalité le dilemme biais-variance (ou dilemme biais-complexité) qui est illustré figure 3 : l'erreur moyenne du minimiseur du risque empirique est majorée par un terme de biais (l'erreur d'approximation) + un terme de variation (l'erreur de fluctuation).

Pour résumer :

- Plus la classe de modélisation $\mathcal{H}$ est grande, meilleure sera la meilleure approximation f^* de f et plus l'erreur de biais sera faible.
- Le terme de biais décroît donc quand $\mathcal{H}$ augmente. À l'inverse, la fluctuation maximum augmente lorsque $\mathcal{H}$ augmente. Si $\mathcal{H}$ est trop grand, le minimiseur du risque empirique $\tilde{f}$ aura tendance à trop coller aux données d'entraînement et ne va pas capturer la régularité du phénomène sous-jacent, qui permet de généraliser le résultat. C'est le phénomène de **sur-apprentissage**.
- L'optimum se situe pour un cardinal de $\mathcal{H}$ tel que ces deux erreurs sont du même ordre comme illustré dans la figure 3. Toute la difficulté va être de trouver des classes $\mathcal{H}$ qui ne sont pas trop grandes et qui produisent une petite erreur d'approximation.

2.2 PAC : Probably Approximatively Correct

Nous démontrons ici le résultat PAC (Probablement Approximativement Correct) qui énonce que l'erreur de fluctuation $\max_{h \in \mathcal{H}} |R(h) - \tilde{R}(h)|$ peut être majorée en probabilité par la taille (ou complexité) de la classe de fonctions $\mathcal{H}$ considérée.

On va montrer que cette erreur de fluctuation peut être arbitrairement petite si n est suffisamment grand, quelque soit la distribution des données (X, Y) . La convergence en probabilité de l'erreur empirique $\tilde{R}(\tilde{f})$ vers l'erreur de généralisation $R(\tilde{f})$ est dans ce cas uniforme par rapport à la loi de (X, Y) .

Intuition :

Pour cela, nous rappelons auparavant que pour un modèle $h \in \mathcal{H}$ fixé, $\tilde{R}(h)$ est un estimateur sans biais de l'erreur de généralisation $R(h)$. L'erreur de fluctuation mesure donc de manière uniforme (car on ne sait pas quelle fonction $\tilde{f}$ sera le minimiseur empirique) l'écart absolu entre l'estimateur $\tilde{R}(h)$ et sa moyenne $R(h)$. On peut mesurer cet écart absolu presque sûrement en probabilité et en moyenne. Presque sûrement, nous savons qu'en moyenne cet écart absolu tend asymptotiquement vers 0 par la loi forte des grands nombres, et en loi nous savons que cet écart tend asymptotiquement vers une gaussienne par le théorème central limite, et donc que cet écart absolu tend vers une valeur absolue de gaussienne. En probabilité, ce type d'écart s'appelle une inégalité de concentration et mesure les probabilités des grandes déviations; en moyenne cet écart représente la variation de notre estimateur.

Théorème 1. Si $\forall h \in \mathcal{H}$ avec $|\mathcal{H}| < \infty$, $R(h) \in [0, 1]$, alors :

$$P\left(\max_{h \in \mathcal{H}} |R(h) - \tilde{R}(h)| \leq \varepsilon\right) \geq 1 - \delta \quad \text{si} \quad \varepsilon^2 = \frac{\log |\mathcal{H}| + \log 2/\delta}{2n} \quad (17)$$

En injectant le théorème 1 précédent dans la proposition 1, on obtient le corollaire suivant :

Corollaire 1. Avec probabilité $\geq 1 - \delta$, on a :

$$R(\tilde{f}) \geq R(f^*) + 2\sqrt{\frac{\log |\mathcal{H}| + \log 2/\delta}{2n}} \quad (18)$$

La preuve est basée sur l'inégalité de concentration de Hoeffding qui contrôle en probabilité les grandes déviations, dont on énonce ici seulement le résultat :

Lemme 1 (Inégalité de Hoeffding). Soit $(Z_i)_{i \leq n}$, une suite de variables aléatoires i.i.d telles que $\forall i \leq n$, $Z_i \in [a, b]$ et $\mathbb{E}(Z_i) = \mu$.

On note $\tilde{\mu}$, la moyenne empirique $\frac{1}{n} \sum_i Z_i$. Alors :

$$\forall \varepsilon > 0, P(|\mu - \tilde{\mu}| \geq \varepsilon) \leq 2 \exp\left(-\frac{2n\varepsilon^2}{(b-a)^2}\right) \quad (19)$$

Ce lemme énonce une décroissance gaussienne de la différence entre une moyenne empirique et la vraie moyenne. Ce résultat peut être vu comme une version non asymptotique du théorème central limite.

Nous allons démontrer le théorème 1 en contrôlant le terme $P(\max_{h \in \mathcal{H}} |R(h) - \tilde{R}(h)| \leq \varepsilon)$ à l'aide du lemme d'Hoeffding et d'une majoration "brutale" d'une union par une somme.

Démonstration. On pose $\mathcal{E}$, l'ensemble des observations $e = (x_i, y_i)$ tel que la différence entre l'erreur empirique et l'erreur de généralisation est supérieure à ε .

$$\begin{aligned}\mathcal{E} &= \{e | \exists h \in \mathcal{H}, |R(h) - \tilde{R}(h)| > \varepsilon\} \\ &= \bigcup_{h \in \mathcal{H}} \{e | |R(h) - \tilde{R}(h)| > \varepsilon\}\end{aligned}$$

Alors :

$$\begin{aligned}P(\mathcal{E}) &\leq \sum_{h \in \mathcal{H}} P(\{e | \exists h \in \mathcal{H}, |R(h) - \tilde{R}(h)| > \varepsilon\}), \quad \text{Par la propriété } P(A \cup B) \leq P(A) + P(B) \\ &\leq \sum_{h \in \mathcal{H}} 2 \exp(-2n\varepsilon^2), \quad \text{Par l'inégalité de Hoeffding pour } [a, b] = [0, 1] \\ &\leq 2|\mathcal{H}| \exp(-2n\varepsilon^2) = \delta\end{aligned}$$

Dès lors, on a bien :

$$\varepsilon^2 = \frac{\log(2|\mathcal{H}|/\delta)}{2n} \quad (20)$$

□

Ce résultat amène à quelques commentaires :

- Si la taille de $\mathcal{H}$ augmente, alors comme on s'y attend la borne supérieure de l'erreur de fluctuation augmente.
- Le terme $\log |\mathcal{H}|$ correspond à l'entropie de la classe $\mathcal{H}$ des prédicteurs (lorsque la distribution de probabilité est uniforme sur la classe). On retrouve ici l'aspect lié à la complexité de $\mathcal{H}$.
- Le résultat a été obtenu en effectuant une majoration brutale d'une union par une somme et peut donc être raffiné.
- En général $\mathcal{H}$ est infini mais peut être paramétré par des paramètres de dimension $m + 1$ dans le cas de la régression / classification linéaire où les paramètres sont $w \in \mathbb{R}^m$ et $b \in \mathbb{R}$.

On peut ainsi quantifier les valeurs de chaque dimension des paramètres sur N valeurs. Puisque $\mathcal{H}$ est paramétré par $m + 1$ paramètres que l'on a quantifiés sur N valeurs, alors $|\mathcal{H}| \sim N^{m+1}$ et donc $\log |\mathcal{H}| \sim (m+1) \log(N)$. Pour que la quantification produise une erreur de l'ordre de ε il faut choisir $N \sim \frac{m}{\varepsilon}$ avec un pas de quantification de l'ordre de $\frac{\varepsilon}{m}$. Pour que l'erreur de fluctuation soit faible et inférieure à ε , on voit par le théorème 1 que l'on doit avoir $\frac{\log |\mathcal{H}|}{n} < \varepsilon^2$ petit et donc $\frac{m}{n} < \varepsilon^2$. On voit ici que le nombre de paramètres de notre algorithme de classification / régression linéaire doit être petit devant le nombre d'exemples.

- Le cas des réseaux de neurones peut sembler aller à l'encontre des résultats formulés : en général, ceux-ci ont plus de paramètres que de nombre d'exemples, mais on arrive malgré tout à de bons, voire très bons, résultats de généralisation. Ce résultat est lié à un phénomène de contractions non linéaires incorporé dans le réseau.

2.3 Étude de 1-NN

L'algorithme du plus proche voisin illustre le phénomène de non-contrôle de l'erreur de fluctuation, lorsque la classe de fonctions $\mathcal{H}$ est trop grande relativement au nombre de données d'entraînement n . Cet algorithme produit une erreur empirique nulle mais il généralise mal car l'erreur de fluctuation est importante.

L'algorithme du plus proche voisin calcule le prédicteur $\tilde{f}$ à partir des données d'entraînement $\{(x_i, y_i)\}_{i \leq n}$ de la manière suivante :

$$\forall x \in \mathbb{R}^d, \tilde{f}(x) = y_i \text{ tq } \|x_i - x\| \leq \min_{i' \neq i} \|x_{i'} - x\| \quad (21)$$

où $\|\cdot\|$ est n'importe quelle norme sur $\mathbb{R}^d$. Cet algorithme découpe l'espace en régions de Voronoï $(V_i)_{i \leq n}$ définies de sorte que :

$$\tilde{f}(x) = \sum_{i=1}^n y_i \mathbf{1}_{\{x \in V_i\}} \quad (22)$$

Comme $\tilde{f}(x_i) = y_i$, l'erreur empirique $\tilde{R}(f)$ vaut 0. En revanche l'erreur de fluctuation est potentiellement très importante pour tout n . En effet, la fonction $\tilde{f}$ appartient à une classe de fonctions $\mathcal{H}_n$ constantes par morceaux définies par l'équation (22) pour tous les $\{(x_i, y_i)\}_{i \leq n}$ possibles. Si les valeurs de x_i et y_i sont quantifiées sur N valeurs alors on a $|\mathcal{H}_n| = N^n$. Comme $\log |\mathcal{H}_n| = n \log(N)$ on voit que la borne supérieure de l'erreur de fluctuation du théorème 1 ne diminue presque pas lorsque n augmente.

Point complexité :

Concernant la complexité de l'algorithme K -NN, ce dernier demande de calculer la distance entre un point $x \in \mathbb{R}^d$ et l'ensemble des points $\{x_i\}_{i \leq n}$, soit une complexité temporelle en $O(nd)$, n pour la taille du jeu de données d'entraînement et d le calcul de la distance en dimension d .

La complexité spatiale requiert de seulement stocker l'ensemble des points, soit $O(n)$.

2.4 Décroissance de l'erreur de généralisation

On a vu dans le théorème 1 que la borne supérieure de l'erreur de fluctuation dépend, à n fixé, de $|\mathcal{H}|$. Pour minimiser cette borne, on veut trouver un ensemble $|\mathcal{H}|$ de fonctions tel que l'erreur d'approximation décroisse le plus rapidement possible avec $|\mathcal{H}|$. Si on équilibre l'erreur d'approximation et l'erreur de fluctuation (intersection des courbes verte et rouge), alors on atteint le minimum à un facteur 2 près.

On va supposer une loi de décroissance de l'erreur d'approximation $R(f^*)$ en fonction de $\log |\mathcal{H}|$. La proposition suivante déduit ainsi une borne supérieure de l'erreur de généralisation pour un nombre d'exemples n suffisamment grand.

Proposition 2. Si il existe $\beta > 0$ et $C > 0$ tels que $R(f^*) \leq C \log |\mathcal{H}|^{-\beta}$, alors :

$$\forall \varepsilon > 0, P(R(\tilde{f}) \leq 3\varepsilon) \geq 1 - 2 \exp\left(-C^{1/\beta} \varepsilon^{-1/\beta}\right) \quad \text{si } n \geq C^{1/\beta} \varepsilon^{-2-1/\beta} \quad (23)$$

Démonstration. On applique le théorème PAC en ajustant δ et $\log |\mathcal{H}|$ en fonction de ε et n .

On pose :

$$\log |\mathcal{H}| = \log(2/\delta) = n\varepsilon^2$$

et donc $\delta = 2e^{-n\varepsilon^2}$. D'après l'inéquation (16), on a :

$$P(\max_{h \in \mathcal{H}} |R(h) - \tilde{R}(h)| \leq \varepsilon) \geq 1 - \delta$$

Or, comme par hypothèse on a $R(f^*) \leq C \log |\mathcal{H}|^{-\beta}$, on en déduit que $R(f^*) \leq \varepsilon$ si :

$$C \log |\mathcal{H}|^{-\beta} \leq \varepsilon$$

et donc :

$$n\varepsilon^2 = \log |\mathcal{H}| \geq C^{1/\beta} \varepsilon^{-1/\beta} \quad (24)$$

Le résultat final est obtenu en appliquant l'équation (17). □

Cette proposition montre que plus l'erreur d'approximation de l'ensemble de classes $\mathcal{H}$ décroît rapidement avec $\log |\mathcal{H}|$ (i.e. plus β est grand), moins on a besoin d'exemples n afin de majorer l'erreur moyenne $R(\tilde{f})$ par une certaine erreur 3ε , et réciproquement. Le problème consiste donc à pouvoir estimer la décroissance de l'erreur d'approximation en fonction de la taille des classes de fonction $\mathcal{H}$ considérées.

2.5 Erreur d'approximation

Nous allons désormais nous concentrer sur l'erreur d'approximation $R(h)$ et calculer une borne supérieure qui ne dépend pas de la distribution de probabilité de X et Y .

On suppose que la réponse y est définie de manière unique à partir de la donnée x , sans ambiguïté, et donc que l'on a $y = f^*(x)$. Dans ce cas :

$$R(f^*) = \min_{h \in \mathcal{H}} d(f^*, h) \quad \text{avec} \quad d(f^*, h) = \mathbb{E}_X[r(f^*(X), h(X))] \quad (25)$$

Par exemple, pour $r(y, \tilde{y}) = (y - \tilde{y})^2$, on définit l'erreur quadratique moyenne.

Suivant l'équation (25), on voit que déterminer f^* et calculer $R(f^*)$ reviennent à résoudre un problème d'approximation de fonctions : on souhaite déterminer la fonction qui se rapproche le plus de la distribution des données.

On ne connaît pas f^* mais on suppose que l'on a de l'information a priori qui permet de garantir que f^* appartient à une classe particulière de fonctions $\mathcal{F}$. Cet a priori sur la classe de fonctions $\mathcal{F}$ va guider le choix des algorithmes et des ensembles d'approximation $\mathcal{H}$. Pour majorer l'erreur pour tout f^* dans $\mathcal{F}$, nous allons contrôler l'erreur maximum :

$$R(f^*) \leq \max_{f \in \mathcal{F}} R(f) \leq \max_{f \in \mathcal{F}} \min_{h \in \mathcal{H}} \|f - h\|_\infty \quad (26)$$

et on va tenter de trouver des bornes d'approximation du type

$$\max_{f \in \mathcal{F}} \min_{h \in \mathcal{H}} \|f - h\|_\infty \leq C \log |\mathcal{H}|^{-\beta} \quad (27)$$

pour pouvoir appliquer la Proposition 2.

L'information a priori que l'on met sur la classe de fonctions $\mathcal{F}$ peut s'interpréter comme une forme de régularité qui explicite le fait que f n'est pas n'importe quelle fonction. Plus une fonction f est "régulière" (dans un sens à définir) moins on aura besoin d'échantillons $(x_i, y_i = f(x_i))$ pour qu'une interpolation de ces échantillons l'approxime bien.

3 Malédiction de la dimensionnalité

La façon la plus intuitive d'appréhender la notion de régularité est à travers le concept de dérivabilité.

Ne possédant pas de définition analytique de nos fonctions, nous allons spécifier la notion de régularité par le biais des fonctions Lipschitziennes qui traduisent une notion de régularité locale de fonction. Nous allons montrer comment la régularité Lipschitziennne se relie à la vitesse d'approximation des fonctions $f(x)$ pour $x \in \mathbb{R}$.

Grâce à ces notions, nous verrons que le nombre d'exemples nécessaires augmente exponentiellement en fonction de d , ce qui n'est pas faisable dès que d est grand.

3.1 Notions sur la régularité de fonction

En dimension 1, la dérivabilité quantifie localement l'amplitude des variations d'une fonction f . Elle se généralise en dimensions supérieures par la différentiabilité au sens de Fréchet ou de Gâteaux. Cependant, on utilise souvent plutôt la notion de régularité Lipschitziennne qui est légèrement plus faible mais plus facile à manipuler.

Définition 6 (Fonction lipschitziennne). Soit $f : \Omega \rightarrow \mathbb{R}$, alors f est une fonction lipschitziennne si :

$$\forall x \in \Omega, \exists C > 0, \forall x' \in \Omega, |f(x) - f(x')| \leq C \|x - x'\| \quad (28)$$

Proposition 3. Soit $f : \Omega \rightarrow \mathbb{R}$, si f est différentiable et que la norme de son Jacobien est bornée en tout point $x \in \mathbb{R}^d$ i.e $\sup_{x \in \mathbb{R}^d} \|\nabla f(x)\| \leq C$ alors f est Lipschitz sur $\mathbb{R}^d$ pour C .

Démonstration. En dimension 1, on montre que :

$$|f(x) - f(x')| = \left| \int_x^{x'} f'(t) dt \right| \leq \int_x^{x'} |f'(t)| dt \leq \int_x^{x'} C dt = C|x - x'|$$

□

La réciproque est plus subtile et débouche sur le théorème de Rademacher :

Théorème 2 (Théorème de Rademacher). Soient Ω un ouvert de $\mathbb{R}^d$ et $f : \Omega \rightarrow \mathbb{R}^m$ une fonction lipschitziennne. Alors f est dérivable presque partout au sens de Gâteaux³ sur Ω .

La régularité lipschitziennne est donc une mesure de régularité très similaire à la dérivabilité directionnelle mais légèrement plus souple. C'est une mesure de régularité locale qui spécifie les variations d'amplitude d'une fonction lorsque l'on bouge autour de points x . De même que l'on peut définir des dérivées d'ordre supérieur, on peut définir des notions de régularité Lipschitziennne d'ordre supérieur de la manière suivante.

Définition 7 (Fonction α -hölérienne). Soient $f : \Omega \rightarrow \mathbb{R}$, alors f est une fonction α -hölérienne si :

$$\forall x \in \Omega, \exists p_x \in K[X] : \deg(p_x) = q \leq \alpha, \forall x' \in \Omega, |f(x') - p_x(x')| \leq C \|x - x'\|^\alpha \quad (29)$$

Où $K[X]$ est l'ensemble des polynômes. Typiquement, p_x peut être interprété comme le polynôme de Taylor d'ordre q .

Une fonction lipschitziennne est dite 1-hölérienne.

3. La différentiabilité au sens de Gâteaux correspond à l'existence des dérivées directionnelles de la fonction f .

Cette régularité d'ordre supérieur mesure la vitesse de décroissance α du résidu entre $f(x')$ et sa meilleure approximation polynomiale p_x partant de x .

Nous allons l'utiliser comme *a priori*, en supposant que les fonctions f que l'on veut apprendre appartiennent à la classe de fonctions $\mathcal{F}_\alpha$, c'est-à-dire des fonctions régulières et dont le résidu à sa meilleure approximation décroît exponentiellement vite :

$$\mathcal{F}_\alpha = \{f : \Omega \rightarrow \mathbb{R} : f \text{ est } \alpha - \text{h\"olderienne}\} \quad (30)$$

L'enjeu va être de contrôler l'erreur d'approximation uniforme $\max_{f \in \mathcal{F}} \min_{h \in \mathcal{H}} \|f - h\|_\infty$ des classes d'approximation $\mathcal{H}$, en fonction de $|\mathcal{H}|$. Pour cela nous allons calculer combien de paramètres et d'exemples il nous faut pour obtenir une erreur d'approximation de l'ordre ε .

3.2 Approximation d'une fonction lipschitzienne par 1-NN

Nous allons considérer l'algorithme du plus proche voisin pour approximer des fonctions qui sont Lipschitz (i.e h\"olderienne $\alpha = 1$).

Cet algorithme ne permet pas de contrôler l'erreur de fluctuation. En effet comme vu section 2.3, on a $\log |\mathcal{H}| = n \log(N)$, ainsi, de l'équation (17), on déduit que $\lim_{n \rightarrow \infty} \varepsilon = \lim_{n \rightarrow \infty} \sqrt{\frac{n \log(N) + \log(2/\delta)}{2n}} = \frac{1}{\sqrt{2}} \approx 0.7$. On a réussi à borner l'erreur par 0.7, ce qui est très peu en considérant une infinité de points !

Toutefois, 1-NN est efficace pour réduire l'erreur d'approximation car il calcule des approximations constantes par morceaux autour des exemples, or la régularité Lipschitzienne contrôle précisément les amplitudes des variations locales.

Malheureusement, nous allons voir qu'en grande dimension, l'erreur d'approximation de l'algorithme du plus proche voisin va décroître très lentement avec le nombre d'exemples ; réciproquement, il nous faudrait un nombre d'exemples gargantuesque pour contrôler l'erreur : c'est la malédiction de la dimensionalité.

Proposition 4. Soient $\mathcal{D} = \{(x_i, y_i) | x_i \in \Omega, y_i \in \Sigma\}_{i \leq n}$ un ensemble d'apprentissage de n données i.i.d et $\mathcal{F}$, la classe des fonctions Lipschitz de constante C sur Ω compact, alors :

$$\sup_{f \in \mathcal{F}} \|f - \tilde{f}\|_\infty = C\varepsilon \quad \text{avec} \quad \varepsilon = \sup_{x \in \Omega} \min_{i \leq n} \{ \|x - x_i\| \} \quad (31)$$

Démonstration. Puisque $f \in \mathcal{F}$ est Lipschitz, $\exists C > 0$ tel que

$$\forall i \leq n, \forall x \in \Omega, \exists C > 0, \forall x \in \Omega, |f(x) - f(x_i)| \leq C \|x - x_i\|$$

Or $\tilde{f}(x) = f(x_i)$ pour $i = \operatorname{argmin}_{i' \leq n} \|x - x_{i'}\|$, donc

$$|f(x) - \tilde{f}(x)| \leq C \min_{i' \leq n} \|x - x_{i'}\|$$

Enfin, on applique le sup de chaque côté :

$$\|f - \tilde{f}\|_\infty = \sup_{x \in \Omega} |f(x) - \tilde{f}(x)| \leq C \sup_{x \in \Omega} \min_{i \leq n} \{ \|x - x_i\| \}$$

Inversement, on va montrer que la borne supérieure est atteinte. Comme Ω est supposé compact, il existe x_j un élément de $\{x_i\}_{i \leq n}$ et $x \in \Omega$ tel que $\|x - x_j\| \leq \|x - x_i\|$ pour tout $i \leq n$ et $\|x - x_j\| = \varepsilon$. La fonction $f(x) = C\|x - x_j\|$ est dans $\mathcal{F}$ et $\|f - \tilde{f}\|_\infty = C\varepsilon$, ce qui montre que la borne supérieure est atteinte. $\square$

Afin de contrôler l'erreur d'approximation il nous faut nous assurer que la distance par rapport à l'exemple le plus proche n'est jamais trop grande.

On va calculer le nombre d'exemples n dont on a besoin en fonction de la dimension d . On suppose que $\Omega = [0, 1]^d$. On se place ici dans le cadre où les exemples sont idéalement répartis, afin d'avoir une borne inférieure sur l'erreur que l'on obtiendrait avec des exemples distribués aléatoirement.

Pour ε fixé, on note $B_\varepsilon(x_i) = \{x' \mid \|x' - x_i\| \leq \varepsilon\}$, la boule de rayon ε autour de l'exemple x_i .

On a $\sup_{x \in \Omega} \min_{i \leq n} \|x - x_i\| \leq \varepsilon$ si et seulement si les $B_\varepsilon(x_i)$ forment un recouvrement de Ω :

$$\Omega \subseteq \bigcup_{i=1}^n B_\varepsilon(x_i) \quad (32)$$

Le recouvrement par un nombre minimum de boules est un problème que l'on rencontre souvent en théorie de l'information. Le rayon ε de la boule correspond à l'erreur maximum de quantification lorsque l'on approxime x par un x_i . Nous allons voir que le nombre de boules nécessaires augmente exponentiellement avec d .

Proposition 5. *La distribution optimale des x_i dans $[0, 1]^d$ satisfait :*

$$\frac{\sqrt{d}n^{-1/d}}{2} \leq \varepsilon \leq \frac{\sqrt{d}n^{-1/d}}{2} \sqrt{\frac{2}{\pi e}} \left(1 + O\left(\frac{d}{\log d}\right)\right) \quad (33)$$

Démonstration. La borne supérieure de la proposition 5 s'obtient avec un échantillonnage de chacune des d directions avec un pas Δ . Le nombre de boules est alors $n = \Delta^{-d}$. Par ailleurs, $\forall x \in \Omega$:

$$\min_i \|x - x_i\|^2 = \sum_{u=1}^d (x(u) - x_i(u))^2 \leq \frac{d\Delta^2}{4}$$

On veut l'erreur la plus grande pour tout $x \in \Omega$, on borne par le sup :

$$\varepsilon = \sup_{x \in \Omega} \min_i \|x - x_i\| \leq \frac{\sqrt{d}n^{-1/d}}{2}$$

On peut cependant faire mieux en optimisant le rangement des boules. La borne inférieure se démontre en observant l'équation (33) et que $Vol(\Omega) = 1$, on obtient :

$$\sum_{i=1}^n Vol(B_\varepsilon(x_i)) = n \times Vol(B_\varepsilon) \geq 1 \quad (34)$$

Or, le volume d'une boule en dimension d peut être approché par la formule suivante :

$$Vol(B_\varepsilon) = \frac{2\pi^{d/2}}{d\left(\frac{d}{2}\right)!} \varepsilon^d$$

Et la formule de Stirling nous donne pour $k \in \mathbb{N}$:

$$k! = \sqrt{2\pi k} \left(\frac{k}{e}\right)^k \left(1 + O\left(\frac{1}{k}\right)\right)$$

Dès lors, on a :

$$\begin{aligned} Vol(B_\varepsilon) &= \frac{\pi^{d/2} \varepsilon^d}{\left(\frac{d}{2e}\right)^{d/2} \sqrt{\pi d}} \left(1 + O\left(\frac{1}{d}\right)\right) \\ &= \left(\frac{d}{2e\pi}\right)^{-d/2} \frac{\varepsilon^d}{\sqrt{\pi d}} \left(1 + O\left(\frac{1}{d}\right)\right) \end{aligned}$$

L'équation (35) implique :

$$n \left(\frac{d}{2e\pi} \right)^{-d/2} \frac{\varepsilon^d}{\sqrt{\pi d}} \left(1 + O \left(\frac{1}{d} \right) \right) \geq 1$$

Par calcul direct, on obtient bien :

$$\varepsilon \geq \frac{\sqrt{d} n^{-1/d}}{2} \sqrt{\frac{2}{\pi e}} \left(1 + O \left(\frac{d}{\log d} \right) \right)$$

□

En insérant la borne inférieure (34) dans (32), on obtient le corollaire suivant.

Corollaire 2. Si $\mathcal{F}$ est la classe des fonctions Lipschitz de constante C sur Ω compact, alors :

$$R(f^*) \leq \sup_{f \in \mathcal{F}} \|f - \tilde{f}\|_\infty \leq C \frac{\sqrt{d} n^{-1/d}}{2} \sqrt{\frac{2}{\pi e}} \left(1 + O \left(\frac{d}{\log d} \right) \right)$$

Et donc, pour atteindre une erreur $C\varepsilon$ il faut donc un nombre d'exemples qui satisfait :

$$n \geq \frac{\varepsilon^{-d} d^{d/2}}{(2\pi e)^{d/2}} \quad (35)$$

Ainsi, d'après l'équation (36), si l'on souhaite borner l'erreur à un $\varepsilon = 0.1$ et que nous sommes en dimension $d = 100$, il faudra un nombre d'exemples $n = 1.924395 \cdot 10^{158}$, ce qui est bien plus que le nombre d'atomes dans l'univers.

De même, si l'on a $\varepsilon = 0.1$ et seulement $n = 100\,000$ exemples à notre disposition, alors, la taille dimension maximale est de $d = 6$. Avec 10 fois plus d'exemples, soit $n = 1$ million, alors on peut pousser en dimension $d = 7$.

Toutefois, notre résultat est à relativiser car nous avons fait l'hypothèse d'une distribution uniforme des points dans l'hypercube Ω . Bien souvent, la distribution n'est pas uniforme, c'est un cas qu'on remarque très facilement avec des images, celles-ci ne sont pas distribuées complètement aléatoirement dans l'espace et font preuve d'une certaine régularité (malgré une variabilité très importante également). Aussi, on peut espérer que le volume réellement intéressant de notre espace est beaucoup plus restreint que celui échantillonné dans notre exemple.

4 Classificateur linéaire, Régularisation et Noyaux

Dans les sections 1.3 et 1.4, nous avons abordé le problème de la classification (resp. régression) en supposant un espace linéarisé par un changement de variable $\phi : \mathbb{R}^d \rightarrow \mathbb{R}^m$.

Également, on a vu que dans ce cas, le classificateur est porté par le vecteur orthogonal au plan $\vec{w}$ et par le biais b . On calcule ensuite le signe du produit scalaire pour savoir de quel côté du plan on se trouve :

$$\tilde{y} = \text{sgn}(\langle w, \phi(x) \rangle - b)$$

Une façon d'interpréter ce changement de variable ϕ est de l'interpréter comme un ensemble d'attributs $\phi(x) = (\varphi_k(x))_{k \leq m}$ et le classificateur prend alors la forme d'une somme pondérée qui peut être vue comme un vote sur l'ensemble des $\varphi_k(x)$. Si $w_k > 0$, alors $\varphi_k(x)$ est un attribut qui vote pour la classe 1 sinon, plutôt pour la classe -1 .

Pour autant, on a **2 problèmes** importants que l'on n'a pas encore abordés :




Figure 4 – Linéarisation de la frontière de décision par ϕ . Une unique direction explique le problème de classification

- **Problème 1** : Comment optimiser les paramètres w et b ?
- **Problème 2** : Comment optimiser le changement de variable ϕ ?

4.1 Optimisation et contrôle du sur-apprentissage

Dans la suite, pour alléger les notations, on considère $\phi(x)$ comme l'identité (i.e. x) et on fusionnera w et b de telle sorte que $w = (w_1, \dots, w_d, b)$ et $x = (v_1, \dots, v_n, 1)$.

De même, nous allons voir dans un premier temps le cadre de la régression, plus simple que celui de la classification. Dans ce dernier cas, une phase de convexification du risque est nécessaire pour pratiquer les différentes étapes que nous allons aborder dans la section.

On rappelle que la classe $\mathcal{H}$ des classificateurs linéaire est telle que :

$$\mathcal{H} = \{h : x \mapsto \langle w, x \rangle \mid w \in \mathbb{R}^{d+1}\} \quad (36)$$

Également, on a vu que l'erreur de fluctuation ε^2 se comporte comme :

$$\varepsilon^2 \sim \frac{\log |\mathcal{H}|}{n} \quad (37)$$

Or, dans ce cas, on voit précisément que $|\mathcal{H}| = \infty$. Pour éviter ce phénomène, on peut avoir recours à la quantification de w comme proposé section 1.3.1. Or pour quantifier ce paramètre, il nous faudrait définir des bornes sur w sans quoi l'espace n'est pas compact.

Nous allons voir dans un premier temps ce qui se passe si on n'impose pas de contrainte sur w et constater que, dans ce cas, on a une instabilité de l'estimateur.

4.1.1 Instabilité du paramètre w

Repartons de l'équation (4) qui donne le risque empirique. Comme c'est un estimateur sans biais de R , on va chercher à optimiser le paramètre w de $h \in \mathcal{H}$ à partir de cette équation.

$$\begin{aligned}\partial_w \tilde{R}(h) = 0 &\iff \frac{2}{n} \sum_{i=1}^n x_i (\langle w, x_i \rangle - y_i) = 0 \\ &\iff \frac{1}{n} \sum_{i=1}^n x_i \langle w, x_i \rangle = \frac{1}{n} \sum_{i=1}^n x_i y_i\end{aligned}$$

Soient la matrice $A = \sum_i x_i x_i^t = X^t X$ et $c = \frac{1}{n} \sum_{i=1}^n x_i y_i$, que l'on pose comme une constante ; alors on obtient un système linéaire de la forme

$$A.w = c \quad (38)$$

et si A est inversible alors :

$$w = A^{-1}c \quad (39)$$

Deux problèmes à nouveau ici :

1. Le premier problème est le cas où la matrice A n'est pas inversible. Ceci peut être résolu en élargissant la notion d'inverse à celle de pseudo-inverse.
2. Le second problème est le cas où l'inverse est instable (i.e. a une norme très grande). Dans ce cas, A^{-1} risque d'amplifier certaines directions de façon violente ; si c change légèrement, alors la réponse fournie risque de complètement changer. On crée un phénomène de sur-apprentissage.

On résout le premier problème : soit $\mathcal{V} = Vect\{x_i\}_{i \leq n}$, l'espace vectoriel généré par l'ensemble de tous les exemples. Si $\mathcal{V} = \mathbb{R}^d$, alors d'après le théorème spectral A est symétrique et peut donc s'écrire :

$$A = P.D.^tP \quad (40)$$

où D est une matrice diagonale et P une matrice orthogonale telle que $P.^tP = I_d$.


De plus, si $\mathcal{V}$ génère l'espace, alors A est inversible et donc D ne peut pas avoir de valeurs propres nulles. Si $\mathcal{V} \subset \mathbb{R}^d$, il n'est pas possible de générer tout l'espace et alors A n'est pas inversible. Dans ce cas, on pose $V = \text{Im}(A)$ et $V^\perp$, l'espace orthogonal à l'image de A . On calcule le pseudo-inverse de A , noté $A^\dagger$ tel que :

$$\begin{cases} A^\dagger c = 0 & \forall c \in V^\perp \\ A^\dagger c = w & \forall c \in V \end{cases} \quad (41)$$

Ainsi, on a :

$$A^\dagger = P.D^\dagger.^tP \quad (42)$$

On précise que dans ce cas, D est la matrice diagonale remplie par les valeurs propres $\sigma_{i \leq k}$ jusqu'au rang $k < d$, puis par des 0 sur le reste de la diagonale. Il vient que :

Figure 5 – Représentation des espaces vectoriels et application par A et pseudo-inverse $A^\dagger$

$$D^\dagger = \begin{pmatrix} \sigma_1^{-1} & & & & \\ & \sigma_2^{-1} & & & \\ & & \ddots & & \\ & & & \sigma_k^{-1} & \\ & & & & 0 \\ & & & & & \ddots \\ & & & & & & 0 \end{pmatrix} \quad (43)$$

Grâce à la technique du pseudo-inverse, on met à 0 toutes les composantes orthogonales à V ; de cette façon, on s'assure que :

$$w = A^\dagger c \in \mathcal{V} \quad (44)$$

Cette formulation est équivalente à :

$$\begin{cases} Aw = c \\ \min ||w||^2 \end{cases} \quad (45)$$

Posons nous désormais la question de la stabilité de notre estimateur w .

Définition 8 (Stabilité). *Un estimateur linéaire w est dit stable si un petit changement sur le jeu de Train implique une faible modification du risque $\tilde{R}(w)$.*

Si w est stable $\Rightarrow$ Pas d'overfitting

Supposons un $\bar{c} \approx c$ résultant d'une petite modification du jeu de Train. On a donc $A\bar{w} = \bar{c}$ et on va essayer de quantifier cette différence au niveau de w , on a :

$$\begin{aligned} ||w - \bar{w}|| &= ||A^\dagger(c - \bar{c})|| \\ &\leq ||A^\dagger|| \times |c - \bar{c}| \end{aligned}$$

Comme on a peu changé le Train, on sait que $|c - \bar{c}| \approx 0$. Reste à quantifier $||A^\dagger||$.

Comme $A^\dagger$ est symétrique, alors sa norme est égale à son rayon spectrale $\rho(A^\dagger)$, soit :

$$\|A^\dagger\| = \rho(A^\dagger) = \max_i \{\sigma_i^{-1}\} \quad (46)$$

Dès lors, pour assurer la régularité de notre modèle (et donc limiter le sur-apprentissage), il est indispensable que les valeurs propres $\sigma_{i \leq d}$ de A ne soit pas trop petites. Dans le cas contraire, au passage à l'inverse, ces quantités vont devenir grandes et provoquer de l'instabilité.

Pour s'assurer que les valeurs σ_i ne soient pas trop petites, on va introduire un terme de régularisation.

4.1.2 Régularisation

On va chercher à minimiser le nouveau risque régularisé $\tilde{R}_\lambda(w)$ par une norme L_2 (i.e. régularisation de Tikhonov ou *Ridge regression*) suivant :

$$\tilde{R}_\lambda(w) = \frac{1}{n} \sum_{i=1}^n (\langle x_i, w_i \rangle - y_i)^2 + \lambda \|w\|^2 \quad (47)$$

Pareil que précédemment, on va chercher à minimiser ce nouveau risque, on obtient :

$$\begin{aligned} \partial_w \tilde{R}_\lambda(w) = 0 &\iff (A + \lambda I_d)w = c \\ &\iff w = (A + \lambda I_d)^{-1}c \end{aligned}$$

Or, $(A + \lambda I_d)$ est toujours inversible (car A est positive), et on déduit que :

$$(A + \lambda I_d)^{-1} = P.(D + \lambda I_d)^{-1}.{}^tP \quad (48)$$

Avec

$$(D + \lambda I_d)^{-1} = \begin{pmatrix} (\sigma_1 + \lambda)^{-1} & & & & \\ & (\sigma_2 + \lambda)^{-1} & & & \\ & & \ddots & & \\ & & & (\sigma_k + \lambda)^{-1} & \\ & & & & \lambda^{-1} \\ & & & & & \ddots \\ & & & & & & \lambda^{-1} \end{pmatrix} \quad (49)$$

Dès lors, on a $\forall i \in \{1, \dots, k\}, \sigma_i + \lambda > \lambda \iff \frac{1}{\sigma_i + \lambda} < \frac{1}{\lambda}$, et donc il suit que :

$$\|(A + \lambda I_d)^{-1}\| \leq \frac{1}{\lambda} \quad (50)$$

On arrive bien à borner l'instabilité et contrôler le phénomène de sur-apprentissage.

Une autre façon de voir le problème posé est de raisonner en terme d'optimisation. En effet, la précédente démarche revient à optimiser sous contraintes le système suivant :

$$\begin{cases} \min \tilde{R}(w) \\ \|w\|^2 \leq \beta \end{cases} \quad (51)$$

Sous cette formulation, on peut interpréter l'équation (52) comme un lagrangien où l'on cherche w dans une classe compact $\mathcal{H}_\beta = \{w | w \in \mathbb{R}^{d+1}, \|w\|^2 \leq \beta\}$.

4.2 Kernel Trick

Maintenant que l'on a une solution analytique à notre problème 1 et qui nous garantit un contrôle sur la solution, attaquons le problème 2. Pour le résoudre, nous allons essayer de trouver un moyen d'augmenter la taille de la dimension grâce au changement de représentation ϕ que nous avons vu figure 4, ceci de façon contrôlée afin de limiter le sur-apprentissage et sans pénaliser la complexité de calcul de nos modèles.

Théorème 3 (Representer Theorem). *Soit l'optimisation du risque régularisé telle que :*

$$\min_w \{ \tilde{R}_\lambda(w) \} \quad (52)$$

Alors, la solution de (52) s'écrit toujours comme une combinaison linéaire des x_i , soit

$$w = \sum_{i=1}^n \alpha_i x_i \quad (53)$$

Et donc $w \in \mathcal{V}$.

Démonstration. Soit $w \in \mathbb{R}^d$, on pose $w = u + v$ tel que $u \in \mathcal{V}$ et $v \in \mathcal{V}^\perp$.

Dès lors, on a :

$$\begin{aligned} \tilde{R}_\lambda(w) &= \frac{1}{n} \sum_{i=1}^n (\langle x_i, (u_i + v_i) \rangle - y_i)^2 + \lambda \|u + v\|^2 \\ &= \frac{1}{n} \sum_{i=1}^n (\langle x_i, u_i \rangle + \langle x_i, v_i \rangle - y_i)^2 + \lambda \|u + v\|^2 \\ &= \frac{1}{n} \sum_{i=1}^n (\langle x_i, u_i \rangle - y_i)^2 + \lambda \|u + v\|^2 \quad \text{Car } v_i \in \mathcal{V}^\perp \\ &= \frac{1}{n} \sum_{i=1}^n (\langle x_i, u_i \rangle - y_i)^2 + \lambda \sqrt{\langle u + v, u + v \rangle} \\ &= \frac{1}{n} \sum_{i=1}^n (\langle x_i, u_i \rangle - y_i)^2 + \lambda \sqrt{\langle u, u \rangle + \langle v, v \rangle + 2\langle u, v \rangle} \\ &= \frac{1}{n} \sum_{i=1}^n (\langle x_i, u_i \rangle - y_i)^2 + \lambda \sqrt{\|u\|^2 + \|v\|^2 + 2\langle u, v \rangle} \\ &= \frac{1}{n} \sum_{i=1}^n (\langle x_i, u_i \rangle - y_i)^2 + \lambda \sqrt{\|u\|^2 + \|v\|^2} \quad \text{Car } u \text{ et } v \text{ sont orthogonaux} \end{aligned}$$

Par conséquent, pour tout $w = u + v$ avec $v \neq 0$, il existe un $w^* = u \in \mathcal{V}$ ayant le même risque empirique mais une norme plus petite, c'est-à-dire un w^* conduisant à une valeur plus faible de la fonction objectif. Inversement, w ne peut être un minimiseur que si sa part dans $\mathcal{V}^\perp$ est égale à 0.

Autrement dit, $w = u = \sum_i \alpha_i x_i \in \mathcal{V}$. □

Ce résultat est très important car il sert à introduire la généralisation de ces techniques aux SVM et à la mise en place de noyaux.

Reprenons l'équation (48) en y incorporant le résultat (54) du Representer Theorem.

$$\tilde{R}_\lambda(w) = \frac{1}{n} \sum_{i=1}^n \left(\left\langle x_i, \sum_{k=1}^n \alpha_k x_k \right\rangle - y_i \right)^2 + \lambda \left\| \sum_{k=1}^n \alpha_k x_k \right\|^2$$

Soit :

$$\tilde{R}_\lambda(w) = \frac{1}{n} \sum_{i=1}^n \sum_{k=1}^n (\alpha_k \langle x_i, x_k \rangle - y_i)^2 + \lambda \sqrt{\sum_{k=1}^n \alpha_k \langle x_k, x_k \rangle} \quad (54)$$

On voit que l'équation (55) ne dépend alors plus que du produit scalaire entre les données x_i, x_k . Deux choses alors :

1. D'une part, l'équation (55) est une fonction convexe ($\langle x_i, x_k \rangle$ est une forme quadratique en α_k).
2. D'autre part, si l'on reprend l'idée de base qui consistait à remplacer les x_i par un changement de variable $\phi(x_i)$, alors les produits scalaires seront remplacés par $\langle \phi(x_i), \phi(x_k) \rangle$.

Ce deuxième point abouti à la technique du *Kernel Trick* qui est une conséquence du théorème de Mercer que nous introduisons ici en sus de la définition d'un noyau :

Définition 9 (Fonction noyau). *Un noyau est une fonction positive, intégrable et à valeurs réelles, notée $K : \Omega \rightarrow \mathbb{R}^+$, qui vérifie les deux conditions suivantes :*

1. *Normalisation* : $\int_{-\infty}^{+\infty} K(x) dx = 1$
2. *Symétrie* : $\forall x \in \Omega, K(-x) = K(x)$

De plus, on dit qu'un noyau est défini positif si :

$$\forall n \in \mathbb{N}, \forall x_1, \dots, x_n \in \Omega, \forall c_1, \dots, c_n \in \mathbb{R}, \sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0$$

Exemple 1. *On cite ici quelques exemples de noyaux :*

- *Noyau linéaire* : $K(x, x') = \langle x, x' \rangle$.
- *Noyau polynomial* : $K(x, x') = (\langle x, x' \rangle + 1)^p, p \geq 1$
- *Noyau gaussien (i.e. RBF)* : $K(x, x') = e^{-\frac{\|x-x'\|^2}{2\sigma^2}}$

Théorème 4 (Théorème de Mercer). *Soit un noyau $K : \Omega \rightarrow \mathbb{R}$ défini positif, alors $\exists \phi : \Omega \rightarrow \mathbb{R}^m$ telle que :*

$$K(x, x') = \langle \phi(x), \phi(x') \rangle \quad (55)$$

Ce théorème est fondamental car il permet, grâce à une fonction noyau, d'effectuer automatiquement un changement de variable ϕ que l'on cherchait à exprimer.

L'idée fondamentale de l'astuce du noyau est de transformer des données dans un espace de dimension supérieure où elles peuvent être linéairement séparables (ou du moins plus séparables qu'elles ne l'étaient dans l'espace d'origine).

De fait, la fonction kernel permet de faire un pont entre l'espace d'origine de dimension d vers des espaces transformés par ϕ de dimension beaucoup plus grande.

Exemple 2. *Soient deux vecteurs $x = (x_1, x_2)$ et $y = (y_1, y_2)$ et $p = 2$.*

La fonction de noyau polynomial donne :

$$K(x, y) = (1 + x_1 y_1 + x_2 y_2)^2 \quad (56)$$

Si nous développons cette expression, nous obtenons :

$$K(x, y) = 1 + 2x_1 y_1 + 2x_2 y_2 + x_1^2 y_1^2 + x_2^2 y_2^2 + 2x_1 x_2 y_1 y_2$$




Figure 6 – Exemple de linéarisation de la frontière de décision d'une variable en 1D par un noyau polynomial de degré $p = 2$

Qui peut être considérée comme un produit scalaire dans un espace de redescription de dimension 6 :

$$K(x, y) = \langle \phi(x), \phi(y) \rangle$$

où

$$\phi(x) = (1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, x_2^2, \sqrt{2}x_1x_2)$$

Ainsi, le noyau polynomial a transformé les données bidimensionnelles originales en données de dimension 6 dans l'espace de redescription.

Exemple 3. L'idée clé derrière le noyau RBF est de mesurer la similarité entre deux points. Si deux points x et y sont très proches, alors $K(x, y)$ sera proche de 1.

Pour voir que l'espace de redescription est infini, il est utile de regarder une expansion de la fonction exponentielle en série de Taylor. On supposera que $\sigma = 1$, soit :

$$K(x, y) = \exp\left(-\frac{1}{2}\|x - y\|^2\right) \quad (57)$$

On rappelle que

$$\exp(z) = \sum_{n=0}^{\infty} \frac{z^n}{n!}$$




Figure 7 – Boule locale de rayon σ traçant une frontière de décision linéaire. La frontière rouge est obtenue par l'union de l'ensemble des frontières linéaires locales.

Si l'on applique cette expansion au noyau RBF avec $z = -\frac{1}{2}\|x - y\|^2$ et $\sigma = 1$, nous obtenons :

$$K(x, y) = 1 - \frac{1}{2}\|x - y\|^2 + \frac{1}{2!} \left(\frac{1}{2}\|x - y\|^2 \right)^2 - \frac{1}{3!} \left(\frac{1}{2}\|x - y\|^2 \right)^3 + \dots$$

On a ainsi $\phi(x) = \left(1, -\frac{1}{\sqrt{2}}x, \frac{1}{2}x^2, -\frac{1}{\sqrt{6}}x^3, \dots \right)$

Revenons au cas général où la valeur de σ n'est pas spécifiée et analysons le développement limité de l'expression. On a

$$DL_0[K(x, y)] = 1 - \frac{\|x - y\|^2}{2\sigma^2} + o(\|x - y\|^2) \quad (58)$$

On se place dans un cas où la distance tend vers 0. Géométriquement, l'équation précédente revient à dresser un rapport entre une distance et des boules de rayon σ de façon à considérer des points à l'intérieur de cette boule.

Deux comportements sont possibles selon σ :

1. Soit $\|x - y\| > \sigma$, alors on considère les points dans un voisinage de rayon σ .
2. Soit $\|x - y\| < \sigma$, alors $K(x, y) \approx 0$, autrement dit les points éloignés au sens du rayon σ n'interagissent pas.

Toutefois, notons que si σ est petit, alors on a une toute petite boule en grande dimension, et donc il est peu probable d'avoir des points dans le voisinage considéré (ref. section 3.2). Dans ce cas, il est crucial d'ajuster σ par cross-validation et grid-search.

4.3 Classification à noyaux et SVM

4.3.1 Critère de la marge




Figure 8 – Classification linéaire

Une première remarque est que dans le cadre de la classification, la frontière de séparation peut ne pas être unique. Comme illustré sur la figure 8a, plusieurs droites peuvent séparer les deux classes sans erreur au sein du jeu d'apprentissage ; pourtant on comprend intuitivement que la droite bleue centrale est meilleure que les deux autres. Cette dernière maximise la *marge*, c'est-à-dire la distance entre les éléments x_1 et x_2 les

plus proches de l'équation de l'hyperplan (ici droite) $\langle w, x \rangle = 0$, ce qui la rend plus "sûre" que les autres droites candidates.

Mettons le problème en équation : on souhaite que l'hyperplan $\langle w, x \rangle = 0$ soit exactement au milieu du point le plus proche à gauche x_1 et du point le plus proche à droite x_2 . Or, les hyperplans parallèles (droites en pointillées sur la figure 8b) qui constituent le "tube de sûreté" sont d'équation $\langle w, x \rangle = \pm c$, où $m \in \mathbb{R}$ est la marge.

On a donc :

$$\begin{cases} \langle w, x_1 \rangle = \|w\|m \\ \langle w, x_2 \rangle = -\|w\|m \end{cases} \quad (59)$$

On normalise w par sa norme de façon que ce que $c = 1$, on obtient alors :

$$\left\langle \frac{w}{\|w\|}, x_1 - x_2 \right\rangle = 2m \iff m = \frac{1}{\|w\|} \quad (60)$$

Maximiser la marge $2m$ (et donc m) revient à minimiser $\|w\|$. Sachant que w est une combinaison linéaire des x_i . Le problème se reformule ainsi :

$$\begin{cases} y_i \langle w, x_i \rangle \geq 1 \\ \min \|w\|^2 \end{cases} \quad (61)$$

Le problème est similaire à celui vu pour la régularisation et va faire intervenir un lagrangien. À la différence, ici on cherche à minimiser la marge sous les n contraintes que les points soient bien classés, soit :

$$\mathcal{L}(w, \lambda) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \lambda_i (1 - y_i \langle w, x_i \rangle) \quad (62)$$

4.3.2 Pénalisation : Soft SVM

Maintenant, la minimisation va bien donner le meilleur hyperplan, encore faut-il qu'il existe. La plupart du temps, il ne va pas exister de classificateur linéaire qui sépare parfaitement tous les échantillons d'entraînement comme sur la figure 8.




Figure 9 – Contraintes du soft SVM et des coûts ξ_i

Dans ce cas de figure, on va chercher un hyperplan qui donne l'erreur de classification minimum. Dans l'article fondateur des SVM⁴, Vapnik propose de définir l'erreur comme la somme des déplacements des points/échantillons mal classés pour les ramener au delà de la marge et les reclassifier correctement.

On note $\xi_i \geq 0$ la distance pour l'échantillon i qu'il faut déplacer, alors

$$y_i \langle w, x_i \rangle \geq 1 - \xi_i \quad (63)$$

Bien entendu, on veut pénaliser ces réarrangements. On reformule le problème comme un problème d'optimisation sous contraintes comme ceci :

$$\begin{cases} \min_{w \in \mathbb{R}^{d+1}} \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \right\}, & C > 0 \\ \text{Contraintes : } y_i \langle w, x_i \rangle \geq 1 - \xi_i, & \xi_i \geq 0, \quad \forall i \in \llbracket 1, n \rrbracket \end{cases} \quad (64)$$

Le paramètre C agit comme un facteur de pondération entre la maximisation de la marge (minimisation de $\|w\|^2$) et la minimisation des erreurs de classification (via les ξ_i). Une valeur plus élevée de C donne plus d'importance à la minimisation des erreurs. Lorsque C tend vers l'infini, le modèle devient très sensible aux erreurs, et la solution tend à sur-apprendre les données d'entraînement.

4.3.3 Convexification du risque

On va chercher à expliciter la forme de ξ_i , on combine l'équation (64) avec la contrainte que $\xi_i \geq 0$, dans le cas où on ne fait pas d'erreur, on peut poser :

$$\xi_i = \max \{1 - y_i \langle w, x_i \rangle, 0\} \quad (65)$$

Finalement, en posant $\bar{y}_i = \langle w, x_i \rangle$ (régression linéaire) et $\tilde{y}_i = \text{sgn}(\bar{y}_i)$, la minimisation à réaliser peut s'écrire :

$$\min \left\{ \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \max \{1 - y_i \bar{y}_i, 0\} \right\} \quad (66)$$

Or la fonction

$$r(y, \bar{y}) = \max(1 - y\bar{y}, 0) \quad (67)$$

n'est autre qu'une **version convexifiée** du risque de classification binaire $r(y, \tilde{y})$ vue équation (3). On appelle ce type de fonction *Hinge Loss*. Ainsi, si $C = \frac{1}{n}$, on retrouve le risque global :

$$\tilde{R}(w) = \frac{1}{n} \sum_{i=1}^n r(y_i, \bar{y}_i) \quad (68)$$

qui est ici bien convexe, et le problème de minimisation se présente comme :

$$\min \left\{ \tilde{R}(w) + \frac{1}{2} \|w\|^2 \right\} \quad (69)$$

Pourquoi la convexité est-elle importante ? Lorsque l'on a un problème d'optimisation convexe, on peut se sentir beaucoup plus confiant dans le fait de trouver un point qui est vraiment optimum global. Par exemple, la convergence de l'algorithme de descente de gradient vers un optimum global est assurée dans le cadre de fonctions convexes.

4. V. Vapnik et A. Lerner, "Pattern Recognition using Generalized Portrait Method", ARC (1963)




Figure 10 – Risque 1/0 convexifié par une Hinge loss

4.4 Conditions de point selle

Pour le SVM avec des contraintes d'inégalité, le lagrangien est formulé en introduisant des multiplicateurs de Lagrange pour chaque contrainte. Le lagrangien $\mathcal{L}$ est donné par :

$$\mathcal{L}(w, b, \xi, \lambda, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \lambda_i [y_i \langle w, x_i \rangle - 1 + \xi_i] - \sum_{i=1}^n \mu_i \xi_i$$

où λ_i (multiplicateurs pour les contraintes de marge) et μ_i (multiplicateurs pour les contraintes sur les variables de pénalité ξ_i) sont les multiplicateurs de Lagrange et sont tous supposés non négatifs.

Pour minimiser $\mathcal{L}$ par rapport à w et ξ , on prend le gradient et on le met à zéro :

1. Par rapport à w :

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial w} &= w - \sum_{i=1}^n \lambda_i y_i x_i = 0 \\ \implies w &= \sum_{i=1}^n \lambda_i y_i x_i \end{aligned}$$

L'équation montre bien que w est une combinaison linéaire des x_i (cf. $\lambda_i y_i = \pm \lambda$). Si $\lambda_i = 0$ alors $1 - y_i \langle w, x_i \rangle < 0$ c'est-à-dire que l'échantillon est au delà de la marge, et donc la contrainte ne s'applique pas.

Donc, le nombre de contraintes "actives" ($\lambda_i > 0$) dépend du nombre de points qui sont sur les deux hyperplans frontières. Finalement, l'algorithme va être piloté non pas par le nombre total d'échantillons, mais uniquement par ceux qui sont les plus proches de l'hyperplan, soit l'ensemble des éléments $\mathcal{I} = \{x_i | i \in \llbracket 1, n \rrbracket, \lambda_i > 0\}$ et donc

$$w = \sum_{i \in \mathcal{I}} (\lambda_i y_i) x_i \quad (70)$$

D'où le vocable « Support Vectors » des échantillons de $\mathcal{I}$.

2. Par rapport à ξ_i :

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \xi_i} &= C - \lambda_i - \mu_i = 0 \\ \implies \lambda_i &= C - \mu_i \end{aligned}$$

En utilisant le théorème de Kuhn et Tucker :

$$\lambda_i [y_i ({}^t w x_i + b) - 1 + \xi_i] = 0$$

$$\mu_i \xi_i = 0$$

et sachant que λ_i et μ_i sont tous deux non négatifs, ainsi que $\xi_i \geq 0$, on a :

$$\lambda_i \leq C$$

puisque $\mu_i \geq 0$.

Après avoir résolu le problème dual, on peut récupérer w à partir des multiplicateurs de Lagrange λ_i et des points de support.

Point complexité :

La famille des régressions kernel / SVM nécessite le calcul de la matrice $\Phi = (K_{nn} + n\lambda I_n)^{-1}Y \in \mathbb{R}^n$ où $K_{nn} = [k(x_i, x_j)]_{i \leq n, j \leq n}$ est la matrice du noyau.

On voit que l'équation ne dépend plus de la dimension mais seulement du nombre d'individus.

Ainsi, on doit calculer l'inverse de la matrice $K_{nn} + n\lambda I_n$ qui nécessite un calcul en $O(n^3)$ et en espace $O(n^2)$.

5 Apprentissage statistique

Jusqu'ici, nous avons abordé la modélisation de nos problèmes en supposant que les données y_i étaient modélisées telles que :

$$y_i = f(x_i) + \varepsilon_i \quad (71)$$

On prend ici un point de vue *déterministe* sur l'hypothèse du modèle en supposant que les données ont été générées par une fonction f .

Or, on peut envisager également la résolution des problèmes de classification / régression d'un point de vue stochastique, c'est-à-dire en considérant qu'une observation y_i est plus probable qu'une autre sachant les données x_i observées.

On se pose alors la question suivante :

Est-il plus facile de résoudre le problème d'apprentissage en grande dimension d'un point de vue déterministe ou stochastique ?

Deux réponses possibles :

	Déterministe	Stochastique
Modèle	$\tilde{y} = \tilde{f}(x)$	$p(\tilde{y} x) = \max_{y \in \Sigma} \{p(y x)\}$
Réponse	Non ! À cause de la malédiction de la dim.	Oui ! J'ai plus de données.

On l'a vu en section 3, l'approche déterministe suppose pour bien fonctionner que la fonction f sous-jacente des données soit suffisamment régulière (lipschitz, ou α -hölderienne) et que les données soient suffisantes et suffisamment denses.

Or, en dimension d , on a également vu que le nombre d'exemples nécessaires était de l'ordre de :

$$n \sim d^{d/2} \quad (72)$$

On l'a vu également, cette approche est assez grossière car elle suppose une répartition uniforme des points dans l'espace.

D'un point de vue stochastique, on envisage plutôt les lignes de niveau de la fonction f :

$$\Omega_y = \{y|f(x) = y\} \quad (73)$$

C'est-à-dire quelles sont les données x qui ont produit l'apparition de y . Et ce qui nous intéresse par la suite, c'est la géométrie de ces lignes (ou surface en dimension supérieure)⁵. Où les points se concentrent-ils dans l'espace ?

L'exemple de la reconnaissance d'images est particulièrement frappant comme illustration de ce phénomène de concentration. D'un point de vue probabiliste, il est très improbable de tomber au hasard sur une image de chien en tirant les pixels de façon aléatoire. On comprend ainsi que l'espace "réellement" occupé, par exemple par les images de chiens, chats, voitures, etc. est tout petit par rapport à l'espace total possible des images quelconques. Le phénomène sous-jacent est la loi des grands nombres que nous allons détailler.

5.1 Point de vue bayésien

Dans le cadre bayésien, on suppose que les couples $(x, y) \in \mathcal{D}$ du jeu de données sont des réalisations de variables aléatoires X, Y . On suppose que ces variables ont une densité de probabilité p selon la mesure de Lebesgue. Dans ce cas, soit une fonction $\tilde{f}$, on peut écrire la fonction de risque de généralisation équation (6), telle que :

$$R(\tilde{f}) = \mathbb{E}_{X,Y}[r(Y, \tilde{f}(X))] = \int_{\mathbb{R}^d} \int_{\Sigma} p(x, y) r(y, \tilde{f}(x)) dy dx \quad (74)$$

Selon la formule de Bayes, on a :

$$p(x, y) = \frac{p(y|x)}{p(x)} \quad (75)$$

Ainsi, on a :

$$R(\tilde{f}) = \int_{\mathbb{R}^d} p(x) \int_{\Sigma} p(y|x) r(y, \tilde{f}(x)) dy dx \quad (76)$$

Deux cas à partir d'ici, soit nous sommes dans un cadre de classification, soit de régression. On détaille ici le cas de la classification. : dans ce contexte, l'équation (77) peut se ré-écrire comme suit sous forme d'une somme discrète sur les éléments de Σ .

$$R(\tilde{f}) = \int_{\mathbb{R}^d} p(x) \sum_{y \in \Sigma} p(y|x) \mathbf{1}_{\{y \neq \tilde{f}(x)\}} dx \quad (77)$$

Dès lors, à x fixé, on veut minimiser la quantité $\sum_{y \in \Sigma} p(y|x) \mathbf{1}_{\{y \neq \tilde{f}(x)\}}$. C'est-à-dire que lorsque la probabilité $p(y|x)$ est grande, on veut que $\mathbf{1}_{\{y \neq \tilde{f}(x)\}}$ soit égale à 0, c'est-à-dire ne pas faire d'erreur.

Ceci revient à choisir la classe la plus probable sachant que l'on observe la donnée x , soit $\tilde{f}$ telle que :

$$\tilde{f}(x) = \tilde{y} \quad \text{t.q.} \quad p(\tilde{y}|x) = \max_{y \in \Sigma} \{p(y|x)\} \quad (78)$$

On reconnaît la formulation analytique du classificateur bayésien.

5.2 Le programme de Fisher

Pour fixer les idées, on considère un jeu de données / échantillon $\mathcal{X} = \{x_i\}_{i \leq n}$ où chaque x_i est issu d'une variable aléatoire X . Formellement, observer n fois la réalisation de la variable X est équivalent à observer une seule fois la réalisation d'un n -uplet $(x_1, \dots, x_n)$ de variables **indépendantes et identiquement distribuées**

⁵. Avoir la vision des lignes de niveau, c'est d'une certaine manière opter pour une vision similaire à celle de l'intégrale de Lebesgue plutôt qu'une intégrale de Riemann qui correspondrait à la vision déterministe.




Figure 11 – Vue schématique d'un réseau convolutionnel

(i.i.d.) qui suivent la même loi que X . Le problème posé est alors de connaître la loi de probabilité qui sous-tend la naissance de ce jeu particulier.

Dans ce contexte, la notion d'**indépendance** (des observations) est la forme de régularité qui va permettre de vaincre la malédiction de la dimension. En effet, si les variables sont indépendantes, alors on a :

$$p(\mathcal{X}) = \prod_{i=1}^n p(x_i) \quad (79)$$

et donc

$$\log p(\mathcal{X}) = \sum_{i=1}^n \log p(x_i) \quad (80)$$

Ainsi, par l'équation (81), il apparaît que le problème peut être vu comme une somme de fonctions à 1 variable, et donc on voit que le problème est beaucoup plus régulier qu'a priori. Il ne s'agit pas de n'importe quelle fonction de tout l'espace fonctionnelle, mais une fonction très particulière, une somme.

Dans l'article "*On the Mathematical Foundations of Theoretical Stats.*" (1922), R. Fisher aborde ces questions relatives à comment définir l'information des données depuis un modèle de probabilité de paramètre θ . Par exemple, considérons la famille des modèles gaussiens paramétrés par $\theta = (\mu, \sigma^2)$ telle que :

$$p_{\theta}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Comment estimer θ à partir de données ?

Fisher développe 4 notions primordiales pour répondre à cette question :

- la notion de **consistance** d'estimateur ; est-ce que l'estimateur converge quand on a une infinité de données, est-il biaisé ou pas ?
- la notion d'inférence par **maximum de vraisemblance**,
- la notion d'**information**, soit à quelle point l'estimation est proche du véritable paramètre θ^* .
- la notion de statistique suffisante ou exhaustive qui rend compte du fait que la statistique (ensemble d'opérations appliquées à un jeu de données) contient toute l'information sur le ou les paramètres de la loi de probabilité sous-jacente.

Toutes ces notions forment la base du programme que constituent les statistiques actuelles.

En outre, ce schéma est à l'oeuvre dans le cas de l'optimisation des réseaux de neurones.

Le problème n'est pas tellement de développer le formalisme décrit précédemment, le grand problème est de spécifier la famille de probabilités $p_{\theta}(x)$. Les réseaux de neurones peuvent être vus comme une façon de spécifier la dite famille.

Par exemple, sur la figure 11, on a schématisé différentes étapes typiques d'un réseau de neurones. On a une cascade de filtres linéaires (ex. convolution), de non-linéarités (ex. ReLU), pour finir par une opération

linéaire qui donne un vecteur $Z_y(x)$ duquel, par une opération `softmax`, on obtient la loi de probabilité $p_\theta(y|x)$ selon :

$$p_\theta(y|x) = \frac{e^{z_y(\theta, x)}}{\sum_{y'} e^{z_{y'}(\theta, x)}} \quad (81)$$

avec y' courant sur l'ensemble des classes à séparer (ex. les digits de 0 à 9). Dans ce contexte, les paramètres θ sont tous les coefficients des filtres convolutionnels et de la linéarité finale.

Le point remarquable est le constat que les familles de probabilités auxquelles les réseaux de neurones permettent d'accéder sont assez génériques pour permettre de résoudre des classes de problèmes très larges comme de l'imagerie, du traitement de texte, de l'audio, de la finance ou de la physique statistique.

5.2.1 La loi des grands nombres : convergence

La convergence vers la moyenne et les phénomènes de concentration sont véritablement tout ce qui donne la puissance aux statistiques.

On considère ici la loi des grands nombres faible qui stipule une convergence en probabilité.

Définition 10 (Loi des grands nombres faible : Convergence). Soit $\mathcal{X} = \{X_i\}_{i \leq n}$ un échantillon de variables aléatoires, alors :

$$\left(\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|X_n - X| \leq \varepsilon) = 1 \right) \iff (X_n \xrightarrow[n \rightarrow \infty]{prob} X), \quad (82)$$

En quelque sorte cette loi nous dit qu'il est rare que X_n se démarque de sa valeur limite X

Théorème 5 (Convergence de moyenne). Soient des variables aléatoires $(X_i)_{i \leq n}$ i.i.d telles que $\mathbb{E}[X_i] = \mu < \infty$, alors

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \longrightarrow \mu \quad (83)$$

La démonstration de ce théorème est un peu technique dans le cas général, mais surtout son principal défaut est de ne pas nous renseigner sur la vitesse de convergence. Nous allons démontrer ce théorème dans le cas où la variance σ^2 existe, c'est-à-dire que $\mathbb{E}[X_i^2] < \infty$.

Démonstration. Soit la variance de la moyenne empirique $\sigma^2(\bar{X}_n)$, alors selon l'hypothèse d'indépendance des variables aléatoires, on a :

$$\sigma^2(\bar{X}_n) = \frac{\sigma^2}{n}$$

Dès lors, plus n augmente, plus $\bar{X}_n$ sera piquée autour de sa moyenne μ , et simultanément les queues de distribution seront faibles.

Le point technique ici est l'inégalité de Tchebychev qui est un résultat de concentration de probabilité :

$$P(|X - E[X]| \geq \alpha) \leq \frac{\sigma^2}{\alpha^2} \quad (84)$$

En combinant les résultats, on a :

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \longrightarrow 0 \quad (85)$$

□

Le résultat important apporté par ce théorème est que la **convergence de $\bar{X}_n$ vers l'espérance μ est en $\frac{1}{n}$ donc assez rapide**, sous hypothèse de variance finie.

5.2.2 Consistance : l'estimation de paramètres

Suivant l'idée de R. Fisher, on se donne n observations et l'on veut estimer la loi de probabilité sous-jacente, en considérant une famille de probabilités paramétrées $p_\theta(x_i)$. Il nous faut alors estimer le "meilleur" θ .

Définition 11 (Consistance). Soit un échantillon $\mathcal{X} = \{X_i\}_{i \leq n}$ et soit $T(\mathcal{X})$, une fonction de n variables aléatoires, on dit que T est un estimateur consistant de θ si

$$T(\mathcal{X}) \longrightarrow \theta \quad (86)$$

Exemple 4. L'estimateur de l'espérance μ est la moyenne empirique $\bar{X}_n$ vu précédemment.

Concernant la variance on peut penser à :

$$S = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 = \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right) - \bar{X}_n^2 \quad (87)$$

Maintenant, il faut vérifier la convergence de (88). Pour ce faire, on utilise le résultat qui stipule qu'une série de variables aléatoires X_n converge vers X en probabilité, et que, pour une fonction continue g , alors on a $g(X_n)$ qui converge vers $g(X)$ en probabilité.

En posant $g(X) = X^2$, on a le résultat souhaité que $\bar{X}_n^2$ converge vers μ^2 si les moments d'ordre 4 $\mathbb{E}[X_i^4] < \infty$. De même en posant $Y_i = X_i^2$, $\bar{Y}$ converge vers l'espérance $\mathbb{E}[X_i^2]$ donc

$$S = \mathbb{E}[X_i^2] - \mu^2 \quad (88)$$

Toutefois, une variable aléatoire fluctue autour de son espérance. On peut donc souhaiter que l'espérance de $\hat{\theta}$ soit égale à θ , autrement dit qu'en « moyenne » l'estimateur ne se trompe pas.

Définition 12 (Biais). Soit un estimateur $\hat{\theta}$ de θ . On dit qu'un estimateur est non biaisé si

$$\mathbb{E}[\hat{\theta}] - \theta = 0 \quad (89)$$

Exemple 5. L'exemple d'estimateur précédent est biaisé. En effet :

$$\sigma^2 = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

Calculons d'abord $\mathbb{E}[\mu^2] = \frac{1}{n^2} \mathbb{E}[(X_1 + \dots + X_n)^2] = \frac{1}{n^2} \mathbb{E}[\sum_i X_i^2 + \sum_i \sum_{i \neq j} X_i X_j]$

Or, par indépendance, $\forall i, X_i = X$, on a $\mathbb{E}[\mu^2] = \frac{1}{n^2} (n\mathbb{E}[X^2] + n(n-1)\mathbb{E}[X]^2)$ et donc

$$\begin{aligned} \mathbb{E}[S] &= \mathbb{E}[X_i^2] - \mathbb{E}[\mu^2] \\ &= n\mathbb{E}[X^2] - \frac{1}{n^2} (n\mathbb{E}[X^2] + n(n-1)\mathbb{E}[X]^2) \\ &= \frac{n-1}{n} \mathbb{E}[X^2] - \frac{n-1}{n} \mathbb{E}[X]^2 \\ &= \frac{n-1}{n} \sigma^2 \end{aligned}$$

On doit corriger par $\frac{n}{n-1}$ pour que l'estimateur soit sans biais.

Maintenant, biais mis à part, on va chercher à obtenir des estimateurs consistants de façon automatique.

5.2.3 Maximum de vraisemblance

Nous donnons la définition de la vraisemblance selon Fisher.

Définition 13 (Maximum de Vraisemblance). Soit $\mathcal{X} = \{X_i\}_{i \leq n}$ où les X_i sont i.i.d, la vraisemblance (likelihood) de ces observations pour un paramètre θ est définie par :

$$\mathcal{L}(\theta, \mathcal{X}) = p_\theta(\mathcal{X}) = \prod_{i=1}^n p_\theta(X_i) \quad (90)$$

Ainsi, on a :

$$\hat{\theta}_{MLE} = \operatorname{argmax}_{\theta \in \Theta} \{\mathcal{L}(\theta, \mathcal{X})\} \quad (91)$$

L'idée de Fisher est de dire que si $\mathcal{L}(\theta_1, \mathcal{X}) > \mathcal{L}(\theta_2, \mathcal{X})$, alors la génération des observations est plus probable si on prend θ_1 que θ_2 . Par abus de langage, on opère un raccourci et on dit souvent " θ_1 est plus probable que θ_2 ".

Exemple 6. On considère la distribution de Laplace définie comme suit :

$$p_\theta(x) = \frac{1}{2} \exp -|x - \theta| \quad (92)$$

On veut en identifier le paramètre θ . Déroulons le formalisme en supposant disposer de n observables :

$$\ell(\theta) = -n \log 2 - \sum_{i=1}^n |x_i - \theta| \Rightarrow \partial_\theta \ell(\theta) = \sum_{i=1}^n \operatorname{sgn}(x_i - \theta) \quad (93)$$

Pour annuler le score il faut qu'il y ait autant de signes positifs que de signes négatifs. Dès lors :

$$\hat{\theta} = \operatorname{median}(\{x_i\}_{i \leq n}) \quad (94)$$

Exemple 7. Prenons désormais la loi Normale, on a :

$$p_\theta(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x - \mu)^2}{2\sigma^2} \right) \quad (95)$$

où $\theta = (\mu, \sigma^2)$. On peut donc choisir de dériver selon μ ou σ selon le paramètre à trouver.

$$\begin{aligned} 0 &= \frac{\partial}{\partial \mu} \ln \left(\left(\frac{1}{2\pi\sigma^2} \right)^{n/2} \exp \left(-\frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \right) \right) \\ &= \frac{\partial}{\partial \mu} \left(\ln \left(\frac{1}{2\pi\sigma^2} \right)^{n/2} - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2} \right) \\ &= \frac{\partial}{\partial \mu} \left(-\frac{\sum_{i=1}^n (x_i^2 + \mu^2 - 2x_i\mu)}{2\sigma^2} \right) \\ &= -\frac{\sum_{i=1}^n (x_i + \mu)}{\sigma^2} \\ &\Rightarrow \mu = \frac{1}{n} \sum_{i=1}^n x_i \end{aligned}$$

Pour le second paramètre, σ , on raisonne de la même façon mais en dérivant selon σ , on trouve $\hat{\sigma}^2 = \sum_{i=1}^n (x_i - \bar{x})^2 / n$.




Figure 12 – Illustration de l'inégalité de Jensen dans le cas convexe

Théorème 6. Soit θ^* le paramètre qui a donné naissance à la probabilité sous-jacente des données de $\mathcal{X}$. On note $\ell(\theta, \mathcal{X}) = \log \mathcal{L}(\theta, \mathcal{X})$ alors :

$$\forall \theta \neq \theta^*, P(\ell(\theta^*, \mathcal{X}) > \ell(\theta, \mathcal{X})) \rightarrow 1 \quad (96)$$

Cette dernière équation confirme l'existence d'un unique paramètre optimale θ^* qui a généré les données.

Démonstration. On divise de part et d'autre l'inéquation dans la probabilité et on ajoute le terme $\frac{1}{n}$, on a par la suite :

$$\frac{\ell(\theta)}{\ell(\theta^*)} = \frac{1}{n} \sum_{i=1}^n \log \frac{p_\theta(X_i)}{p_{\theta^*}(X_i)} < 0 \quad (97)$$

sous l'hypothèse que $n \rightarrow \infty$, on reconnaît ici l'espérance, on a donc :

$$\mathbb{E}_X \left[\log \frac{p_\theta(X_i)}{p_{\theta^*}(X_i)} \right] < 0 \quad (98)$$

Or, le logarithme est une fonction concave, et l'inégalité de Jensen illustrée figure 12 nous donne que :

$$\phi, \text{ fonction concave} \Rightarrow \phi(\mathbb{E}[X]) \geq \mathbb{E}[\phi(X)]$$

la stricte concavité induit une inégalité stricte. Ainsi, on sait que :

$$\mathbb{E}_X \left[\log \frac{p_\theta(X_i)}{p_{\theta^*}(X_i)} \right] < \log \left(\mathbb{E}_X \left[\frac{p_\theta(X_i)}{p_{\theta^*}(X_i)} \right] \right) \quad (99)$$

Or, les observables sont tirés selon la loi p_{θ^*} , donc :

$$\mathbb{E}_X \left[\frac{p_\theta(X_i)}{p_{\theta^*}(X_i)} \right] = \int \frac{p_\theta(x)}{p_{\theta^*}(x)} p_{\theta^*}(x) dx = 1 \quad (100)$$

On conclut par le théorème des gendarmes.

□

Démontrons désormais la consistance du MLE.

Théorème 7 (Consistance du MLE). Lorsque $n \rightarrow \infty$, alors $\hat{\theta}_{MLE} \rightarrow \theta^*$

Démonstration. On va montrer qu'il existe une unique séquence de MLE $\hat{\theta}_n$ qui converge en probabilité vers θ^* ⁶.

6. On raisonne en 1D, mais la démonstration peut se généraliser en dimension supérieure.

Soit $a > 0$ défini tel que $[\theta^* - a, \theta^* + a] \subset \tilde{\Theta}$, où $\tilde{\Theta}$ est l'ensemble ouvert des estimateurs. On pose S_n , l'ensemble des échantillons $\mathcal{X}$ de taille n tel que :

$$S_n = \{\mathcal{X} | \ell(\theta^*, \mathcal{X}) > \max\{\ell(\theta^* - a, \mathcal{X}), \ell(\theta^* + a, \mathcal{X})\}\} \quad (101)$$

D'après le théorème 6, on a :

$$P(S_n) \rightarrow 1$$

En d'autres termes, presque tous les échantillons vont appartenir à S_n .

Dans l'intervalle $[\theta^* - a, \theta^* + a]$, comme $\ell(\theta, \mathcal{X})$ est dérivable selon θ , elle est continue et, d'après le théorème de Rolle, il existe une valeur θ qui annule $\partial_\theta \ell(\theta, \mathcal{X})$, on la note $\hat{\theta}_n$.

Ainsi, on définit l'ensemble $\hat{S}_n$ tel que :

$$\hat{S}_n = \{\mathcal{X} | \exists \hat{\theta}_n \in [\theta^* - a, \theta^* + a], \partial_\theta \ell(\hat{\theta}_n, \mathcal{X}) = 0 \wedge \|\theta^* - \hat{\theta}_n\| < a\} \quad (102)$$

On sait que $S_n \subset \hat{S}_n$, car en effet, on a moins de contraintes au sein de S_n . Dès lors $P(S_n) \leq P(\hat{S}_n)$. Par passage à la limite en probabilité, il vient que :

$$P(\hat{S}_n) \rightarrow 1$$

□

Ainsi, pour tout $a > 0$, en probabilité on trouvera un $\hat{\theta}_n$ proche de θ^* . On a donc notre théorème, à l'ajustement près qu'à chaque étape n , on prend une valeur $\hat{\theta}_n$ s'il y en a plusieurs afin de constituer la séquence qui converge vers θ^* . Cette séquence peut être obtenue par les itérations de la descente de gradient par exemple.

5.2.4 Information de Fisher

La question qui vient après avoir montré que le MLE est un estimateur constant, est de savoir si l'on peut faire mieux pour estimer θ^* ? On se pose alors la question de l'efficacité de l'estimateur MLE.

L'idée sous-jacente est de quantifier la quantité d'information que des observations vont donner sur le paramètre θ .

Pour commencer, on suppose les deux règles suivantes :

1. La densité de probabilité p_θ est deux fois dérivable par rapport à θ .
2. Le théorème de convergence dominée

$$\left(\int p_\theta dx \right)'' = \int p_\theta'' dx$$

c'est-à-dire que la dérivée seconde de la probabilité doit être dominée, ce qui est le cas en pratique.

Envisageons le score $s(\theta, \mathcal{X})$ suivant :

$$s(\theta, \mathcal{X}) = \frac{\partial \ell(\theta, \mathcal{X})}{\partial \theta} \quad (103)$$

Par définition du MLE, on a $s(\hat{\theta}, \mathcal{X}) = 0$. Pour $\theta = \theta^*$ qui donne la vraie distribution des observables alors :

$$\mathbb{E}_{\mathcal{X} \sim p_{\theta^*}} [s(\theta^*, \mathcal{X})] = 0 \quad (104)$$

Ceci nous donne une définition de l'Information de Fisher.

Définition 14 (Information de Fisher). *L'Information de Fisher est la variance du score $s(\theta, \mathcal{X})$ calculée en θ^* , soit :*

$$I(\theta^*) = \mathbb{E}_{\mathcal{X} \sim p_{\theta^*}} \left[\left(\frac{\partial \log p_{\theta}(\mathcal{X})}{\partial \theta} \Big|_{\theta=\theta^*} \right)^2 \right] = \text{Var}_{\mathcal{X} \sim p_{\theta^*}} [s(\theta^*, \mathcal{X})] \quad (105)$$

Ainsi, si l'information est importante, alors cela traduit que l'on est très sensible aux variations de l'estimation du maximum de vraisemblance lorsque l'on fait des tirages de données. Étant très sensible, on est donc mieux à même de déterminer θ^* . Pour exprimer cette intuition, on montre le résultat suivant :

Lemme 2. *L'Information de Fisher est reliée à la courbure du log-likelihood calculée en θ^* , c'est-à-dire :*

$$I(\theta^*) = -\mathbb{E}_{\mathcal{X} \sim p_{\theta^*}} \left[\frac{\partial^2 \log p_{\theta}(\mathcal{X})}{\partial \theta^2} \Big|_{\theta=\theta^*} \right] \quad (106)$$

Nous allons utiliser l'information de Fisher pour poser une borne à la précision d'estimation du paramètre θ^* . Si on se place dans un problème d'apprentissage, θ est l'ensemble des paramètres d'un réseau, et l'on veut estimer la précision avec laquelle on les détermine.

Théorème 8 (Borne de Cramér-Rao). *Soit $\mathcal{X} = \{x_i\}_{i \leq n}$ un échantillon d'observations i.i.d qui sont toutes distribuées selon une distribution p_{θ^*} . On considère un estimateur $\hat{\theta}$ de θ^* et on note $\tau(\theta^*) = \mathbb{E}_{\mathcal{X} \sim p_{\theta^*}} [\hat{\theta}]$. Dès lors, la variance de $\hat{\theta}$ est bornée selon :*

$$\text{Var}(\hat{\theta}) \geq \frac{|\tau'(\theta^*)|}{n I_1(\theta^*)} \quad (107)$$

où on note $I_1(\theta^*)$ l'information de Fisher de 1 observation.

Corollaire 3. *Dans le cadre où $\hat{\theta}$ est un estimateur non biaisé, alors $\tau(\theta^*) = \theta^*$, alors :*

$$\text{Var}(\hat{\theta}) \geq \frac{1}{n I_1(\theta^*)} \quad (108)$$

Démonstration. La stratégie de la démonstration passe par le calcul direct de $\tau'(\theta^*)$. Il vient en utilisant le caractère i.i.d. des observations et les résultats sur le score :

$$\begin{aligned} \tau(\theta^*) &= \int p_{\theta^*}(\mathcal{X}) \hat{\theta} d\mathcal{X} = \int \hat{\theta} \prod_{i=1}^n p_{\theta^*}(x_i) dx_1, \dots, dx_n \\ \Rightarrow \tau'(\theta^*) &= \int \hat{\theta} \sum_{i=1}^n \underbrace{p'_{\theta^*}(x_i)}_{(\log p_{\theta^*}(x_i))'} \frac{1}{p_{\theta^*}(x_i)} \prod_{j=1}^n p_{\theta^*}(x_j) dx_1 \dots dx_n \\ &= \int \hat{\theta} \frac{\partial \log p_{\theta^*}(x_1, \dots, x_n)}{\partial \theta^*} \prod_{j=1}^n p_{\theta^*}(x_j) dx_1 \dots dx_n \\ &= \int \hat{\theta} \frac{\partial \log p_{\theta^*}(\mathcal{X})}{\partial \theta^*} p_{\theta^*}(\mathcal{X}) d\mathcal{X} \\ &= \mathbb{E}_{\mathcal{X} \sim p_{\theta^*}} [\hat{\theta} \times s(\theta^*, \mathcal{X})] = \text{Cov}[\hat{\theta} \times s(\theta^*, \mathcal{X})] + \underbrace{\mathbb{E}[\hat{\theta}] + \mathbb{E}[s(\theta^*, \mathcal{X})]}_{=0} \end{aligned}$$

Par l'inégalité de Cauchy-Schwarz, on a :

$$|\tau'(\theta^*)| = |\text{Cov}_{\mathcal{X} \sim p_{\theta^*}} [\hat{\theta} \times s(\theta^*, \mathcal{X})]| \leq \text{Var}[\hat{\theta}] \times \text{Var}[s(\theta^*, \mathcal{X})] = \text{Var}[\hat{\theta}] \times I(\theta^*) \quad (109)$$

□

Ce résultat de Cramér-Rao est à la fois très important pour comprendre comment procéder à de l'inférence de paramètres, et assez singulier car il est rare d'avoir une borne explicite de la limite d'un estimateur. Le travail principal qui mobilise toute l'attention des chercheurs qui font de l'inférence, c'est de trouver les estimateurs des paramètres sous-jacent du modèle qui ont la plus grande information de Fisher.

Le formalisme précédent se généralise aisément au cas multidimensionnel où $\theta \in \mathbb{R}^d$. On a déjà expérimenté que la dérivée selon θ devient le gradient, ainsi

$$\nabla_{\theta} \ell(\hat{\theta}, \mathcal{X}) = 0 \quad \mathbb{E}_{\mathcal{X}}[\nabla_{\theta} \ell(\theta^*, \mathcal{X})] = \mathbb{E}_{\mathcal{X}}[s(\theta^*, \mathcal{X})] \quad (110)$$

et l'information de Fisher devient :

$$I(\theta^*) = \mathbb{E}_{\mathcal{X}}[||\nabla_{\theta} \ell(\theta^*, \mathcal{X})||^2] = -\mathbb{E}_{\mathcal{X}}[H[\ell](\theta^*, \mathcal{X})] \quad (111)$$

Où H est le hessien. Ainsi, on voit que l'information de Fisher gouverne la vitesse de convergence de l'algorithme de descente de gradient. On comprend mieux le lien entre optimisation et précision à travers la géométrie de la surface de la famille des probabilités.

5.3 Étude de la régression logistique

On considère un ensemble de données $\mathcal{D} = \{(x_i, y_i) | x_i \in \mathbb{R}^d, y_i \in \{-1, 1\}\}_{i \leq n}$ où n est le nombre de données. On définit le classificateur logistique tel que :

$$p_{\theta}(y_i = 1 | x_i) = \frac{e^{\langle x_i, \theta \rangle}}{1 + e^{\langle x_i, \theta \rangle}} \quad (112)$$

Le modèle logistique est une version généralisée du modèle linéaire où se dernier ajuste un modèle évidentiel de la forme :

$$\ln\left(\frac{p}{1-p}\right) = \langle x_i, \theta \rangle \quad (113)$$

Si l'on pose $p = p_{\theta}(y_i = 1 | x_i)$, alors après résolution, on a bien l'équation (113).

On considère désormais le modèle généralisé où $y \in \{c_1, \dots, c_k\}$, dans ce cas, on peut considérer un ensemble de classifieurs simples que l'on normalise, on obtient ainsi :

$$p_{\theta}(y|x) = \frac{e^{\langle x, \theta_y \rangle}}{\sum_y e^{\langle x, \theta_y \rangle}} = \text{softmax}(\langle x, \theta_y \rangle) \quad (114)$$

avec $x \in \mathbb{R}^d$, et l'objectif est de trouver les directions privilégiées $\hat{\theta}$ qui pointent vers les y zones où les observations ayant les mêmes labels s'agrègent car alors on choisira comme estimateur de la classe pour une nouvelle observation x le label tel que

$$\tilde{y} = \text{argmax}_y p_{\hat{\theta}}(y|x) \quad (115)$$

Concernant le lien entre le classificateur logistique et la fonction sigmoid $\sigma : \mathbb{R} \rightarrow [0, 1]$ définie telle que

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (116)$$

On remarque que (113) peut se ré-écrire selon $\sigma(\langle x_i, \theta \rangle)$. Ce fait est intéressant car la fonction sigmoid se dérive très bien, en particulier, on a $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ ce qui peut être utile lors du calcul de la




Figure 13 – Schématisation de l'objectif d'une classification logistique qui tente de trouver les directions θ_y pointant vers les différentes zones d'agrégats d'observations ayant le même label.

descente de gradient et l'utilisation de l'algorithme de Newton-Raphson.

Revenons désormais sur la fonction de vraisemblance. Celle-ci pour la régression logistique est dérivée à partir de la probabilité conditionnelle des résultats observés. Pour une série d'observations indépendantes (y_i, x_i) , où y_i est la variable de réponse binaire et x_i est le vecteur des prédicteurs pour l'observation i , on a notre modèle régit par une loi de Binomiale ; la vraisemblance est alors le produit des probabilités individuelles :

$$L(\theta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i} \quad (117)$$

où $p_i = \frac{1}{1+e^{-(\theta_0+\theta_1 x_{i1}+\dots+\theta_d x_{id})}}$ est la probabilité prédite que $y_i = 1$ étant donné x_i et les paramètres θ .

Pour simplifier le calcul, on utilise la log-vraisemblance :

$$\log L(\theta) = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \quad (118)$$

Pour utiliser la descente de gradient, nous devons calculer le gradient de la log-vraisemblance.

$$\frac{\partial \log L(\theta)}{\partial \theta_j} = \sum_{i=1}^n x_{ij}(y_i - p_i) \quad (119)$$

où x_{ij} est la valeur de la j -ième variable prédictive pour l'observation i , et $y_i - p_i$ est la différence entre l'observation réelle et la probabilité prédite.

La descente de gradient met à jour les paramètres à chaque étape en soustrayant un multiple du gradient de la valeur actuelle des paramètres :

$$\theta_{n+1} = \theta_n - \eta \nabla_{\theta} \log L(\theta_n) \quad (120)$$

où $\eta > 0$ est le taux d'apprentissage, un hyperparamètre qui détermine la taille des pas des mises à jour. De plus, on a vu dans le TD2 que sous certaines conditions de convexité et de régularité, on sait que $\theta_n \rightarrow \theta^*$.

Point complexité :

En terme de complexité, le calcul du gradient nécessite environ $O(nd)$ opérations ; nous déduisons, si on effectue T itérations, une complexité en temps de l'ordre de $O(ndT)$. La complexité spatiale est bornée par la taille de matrice des données, soit $O(nd)$.

Pour conclure et généraliser à des dimensions supérieures, on peut se pencher sur le Hessien, c'est-à-dire la

matrice des secondes dérivées partielles de la log-vraisemblance, qui joue un rôle crucial dans l'efficacité de la convergence de la méthode de Newton-Raphson, utilisée dans des optimisations de la descente de gradient. En effet, un Hessien mal conditionné peut mener à une convergence lente ou instable. Le conditionnement est le rapport $\frac{\lambda_{\min}}{\lambda_{\max}}$ et fait référence à la mesure dans laquelle une petite modification des valeurs d'entrée affecte les valeurs de sortie. Un Hessien bien conditionné a un écart relativement faible entre ses valeurs propres. Pour améliorer le conditionnement, on peut utiliser la régularisation, comme la régularisation de Ridge que nous avons déjà vue section 4.1, qui ajoute un terme de pénalité à la fonction de coût.

6 Synthèse sur la complexité des algorithmes

Nous dressons le tableau qui synthétise la complexité des algorithmes que nous avons balayés :

Modèle	Complexité temporelle	Complexité spatiale
Régression linéaire	$O(d^3)$	$O(d^2 + nd)$
K -NN	$O(nd)$	$O(n)$
Régression Kernel / SVM	$O(n^3)$	$O(n^2)$
Régression Logistique	$O(ndT)$	$O(nd)$

On pourra retrouver plus de détails sur la démonstration des complexités à la section de l'algorithme concerné.