

Théorie des langages et automates

Grammaires formelles – 1

Clément Moreau^{1,2}

¹BRED – Banque Populaire — clement.moreau@bred.fr

²Université de Tours

1 Grammaire formelle

2 Exemples de grammaire

- Problème des parenthèses
- Grammaire des expressions arithmétiques

3 Grammaires ambiguës

Table of Contents

1 Grammaire formelle

2 Exemples de grammaire

- Problème des parenthèses
- Grammaire des expressions arithmétiques

3 Grammaires ambiguës

Dans l'étude des langages formels ou naturels, une *grammaire* est un ensemble de règles qui dicte la nature des phrases ou mots construits.

Dans l'étude des langages formels ou naturels, une *grammaire* est un ensemble de règles qui dicte la nature des phrases ou mots construits.

Par exemple, considérons l'ensemble de règles suivants :

$\langle phrase \rangle$	\rightarrow	$\langle sujet \rangle \langle predicat \rangle$
$\langle sujet \rangle$	\rightarrow	le chien le chat le bébé
$\langle predicat \rangle$	\rightarrow	$\langle verbe \rangle \langle adverbe \rangle$ $\langle verbe \rangle \langle sujet \rangle$
$\langle verbe \rangle$	\rightarrow	mange
$\langle adverbe \rangle$	\rightarrow	sagement proprement ε

Dans l'étude des langages formels ou naturels, une *grammaire* est un ensemble de règles qui dicte la nature des phrases ou mots construits.

Par exemple, considérons l'ensemble de règles suivants :

$\langle phrase \rangle$	\rightarrow	$\langle sujet \rangle \langle predicat \rangle$
$\langle sujet \rangle$	\rightarrow	le chien le chat le bébé
$\langle predicat \rangle$	\rightarrow	$\langle verbe \rangle \langle adverbe \rangle$ $\langle verbe \rangle \langle sujet \rangle$
$\langle verbe \rangle$	\rightarrow	mange
$\langle adverbe \rangle$	\rightarrow	sagement proprement ε

On appelle ici *variable*, les termes entre $\langle \rangle$ et *symboles finaux* les mots en français et police droite.

On peut générer une phrase à l'aide de notre grammaire de la façon suivante :

- 1 On part de la variable $\langle phrase \rangle$.
- 2 On remplace successivement toutes les variables à droite de la règle jusqu'à obtenir des symboles finaux.

Exemples

$\langle phrase \rangle \Rightarrow \langle sujet \rangle \langle predicat \rangle$
 $\Rightarrow \text{le chien} \langle predicat \rangle$
 $\Rightarrow \text{le chien} \langle verbe \rangle \langle adverbe \rangle$
 $\Rightarrow \text{le chien mange} \langle adverbe \rangle$
 $\Rightarrow \text{le chien mange sagement}$

Une grammaire permet de décrire un langage de manière inductive.

Définition

Une *grammaire formelle* G est un quadruplet :

$$G = (V, \Sigma, P, S)$$

avec :

- V — un ensemble fini de variables (symboles non terminaux), chaque variable représente un ensemble de mots.
- Σ — un ensemble fini de symboles (un alphabet) tel que $V \cap \Sigma = \emptyset$ dont les éléments sont appelés les symboles terminaux.
- P — un ensemble fini de règles de production
- $S \in V$ — l'axiome, qui représente tous les mots décrits par la grammaire.

Grammaire formelle

Soient une grammaire $G = (V, \Sigma, P, S)$, des mots $\alpha, \beta \in (V \cup \Sigma)^*$ et une variable $A \in V$. S'il existe une règle de production $A \rightarrow \gamma$, alors

$$\alpha A \beta \Rightarrow \alpha \gamma \beta$$

. Le symbole \Rightarrow indique une règle de *dérivation* de la grammaire.

- On note \Rightarrow^* la fermeture réflexive et transitive de \Rightarrow .
- On note aussi par $\alpha \Rightarrow^n \beta$ s'il existe $\alpha_0, \dots, \alpha_n$ tels que $\alpha_0 = \alpha$ et $\alpha_n = \beta$ et $\alpha_i \Rightarrow \alpha_{i+1}$, pour $0 \leq i < n$.
- À chaque étape, il est possible de dériver la variable la plus à gauche ou de dériver la variable la plus à droite.

Langage d'une grammaire

Le langage d'une grammaire est défini tel que :

$$L(G) = \{u \mid u \in \Sigma^*, S \Rightarrow^* u\}$$

Exemples

- 1 Soit la grammaire $G = (\{S\}, \{0, 1\}, \{S \rightarrow \varepsilon | 0S1\}, S)$.
Quelle est langage décrit par G ?
- 2 Donner la grammaire permettant de représenter le langage des palindromes sur l'alphabet $\{0, 1\}$.

Grammaire linéaire

Une grammaire G est *linéaire* si toutes les règles de production sont de la forme $A \rightarrow a$ $A \rightarrow aB$ (resp. $A \rightarrow Ba$) ou $S \rightarrow \varepsilon$ où $A, B \in V$ et $a \in \Sigma$.

- $\forall p \in P, p : A \rightarrow aB, G$ est linéaire à droite $\Rightarrow G$ est régulière.
- $\forall p \in P, p : A \rightarrow Ba, G$ est linéaire à gauche $\Rightarrow G$ est régulière.
- $\forall p \in P, p : A \rightarrow aBb, G$ est linéaire $\Rightarrow G$ **n'est pas forcément régulière**.

Grammaire linéaire

Une grammaire G est *linéaire* si toutes les règles de production sont de la forme $A \rightarrow a$ ou $A \rightarrow aB$ (resp. $A \rightarrow Ba$) ou $S \rightarrow \varepsilon$ où $A, B \in V$ et $a \in \Sigma$.

- $\forall p \in P, p : A \rightarrow aB, G$ est linéaire à droite $\Rightarrow G$ est régulière.
- $\forall p \in P, p : A \rightarrow Ba, G$ est linéaire à gauche $\Rightarrow G$ est régulière.
- $\forall p \in P, p : A \rightarrow aBb, G$ est linéaire $\Rightarrow G$ n'est pas forcément régulière.

Exemples

Proposer une grammaire linéaire capable de générer les langages réguliers suivants du TD1 :

- 1 L'ensembles des mots qui finissent en 00.
- 2 L'ensemble des mots qui contiennent un nombre pair de sous-mots 01.
- 3 L'ensemble des mots sur $\{a\}$ tel que le mot possède une longueur qui est un multiple de 3 ou de 5 (ex. aaa,aaaaa,aaaaaa)

Définition

Une grammaire $G = (V, \Sigma, P, S)$ est dite *non-contextuelle* (ou hors-contexte) si toutes les règles de production sont de la forme $A \rightarrow \alpha$ où $A \in V$ et $\alpha \in \{V \cup \Sigma\}^*$

Théorème

Pour tout langage $L \in \mathbf{Reg}$, il existe une grammaire non-contextuelle G telle que $L = L(G)$.

Démonstration.

Soit $L \in \mathbf{Reg}$, dès lors on sait qu'il existe un AFD $M = (Q, \Sigma, q_0, \delta, F)$ tel que $L(M) = L$.

Posons une grammaire $G = (V, \Sigma, P, S)$ telle que $V = Q$ et $S = q_0$ et

$$P = \{q \rightarrow ap \mid \delta(q, a) = p\} \cup \{f \rightarrow \varepsilon \mid f \in F\}$$

Par induction, on peut prouver que $\forall p, q \in Q$ et $\forall x \in \Sigma^*$, $\delta(q, x) = p$ si et seulement il existe une dérivation $q \Rightarrow^* xp \in G$.

En particulier, $x \in L$ si et seulement si il existe une dérivation de la forme

$$q_0 \Rightarrow^* xf \Rightarrow x$$

pour tout état $f \in F$. Ce qui montre que $L \subseteq L(G)$. De plus, comme G est linéaire à droite, les dérivations de la forme ci-dessus sont les seules de G . Dès lors, $L = L(G)$. □

Définition

Une grammaire $G = (V, \Sigma, P, S)$ est dite *contextuelle* si toutes les règles de production sont de la forme $\phi A \psi \rightarrow \phi \alpha \psi$ où $A \in V$ et $\alpha, \phi, \psi \in (V \cup \Sigma)^*$ et $\alpha \neq \varepsilon$.

Définition

Une grammaire $G = (V, \Sigma, P, S)$ est dite *contextuelle* si toutes les règles de production sont de la forme $\phi A \psi \rightarrow \phi \alpha \psi$ où $A \in V$ et $\alpha, \phi, \psi \in (V \cup \Sigma)^*$ et $\alpha \neq \varepsilon$.

Exemples

Soit le langage $L = \{a^n b^n c^n | n \geq 0\}$, engendré par la grammaire contextuelle :

$$\begin{aligned} S &\rightarrow \varepsilon | abc | aAbc \\ Ab &\rightarrow bA \\ Ac &\rightarrow Bbcc \\ bB &\rightarrow Bb \\ aB &\rightarrow aa | aaA \end{aligned}$$

Vérifier que le mot $aaabbbcccc$ est bien produit par la grammaire. On adoptera une dérivation à gauche.

Table of Contents

1 Grammaire formelle

2 Exemples de grammaire

- Problème des parenthèses
- Grammaire des expressions arithmétiques

3 Grammaires ambiguës

Problème des parenthèses

Le *problème des parenthèse* revient à déterminer une formalisation à partir d'une grammaire non-contextuelle du langage PAREN reconnaissant les expressions correctement parenthésées.

Problème des parenthèses

Le *problème des parenthèse* revient à déterminer une formalisation à partir d'une grammaire non-contextuelle du langage PAREN reconnaissant les expressions correctement parenthésées.

Langage PAREN

Soit $x \in \{[,]\}^*$. On donne les notations suivantes :

- $G(x) = |x|_l =$ Le nombre de parenthèses ouvrantes de x .
- $D(x) = |x|_r =$ Le nombre de parenthèses fermantes de x .

Ainsi, PAREN est le langage des mots x qui respectent les deux axiomes suivants :

- 1 $G(x) = D(x)$, et
- 2 Pour tout préfixe $y = x_1 \dots x_{k \leq |x|}$ de x , $G(y) \geq D(y)$.

Problème des parenthèses

Le *problème des parenthèse* revient à déterminer une formalisation à partir d'une grammaire non-contextuelle du langage PAREN reconnaissant les expressions correctement parenthésées.

Langage PAREN

Soit $x \in \{[,]\}^*$. On donne les notations suivantes :

- $G(x) = |x|_l =$ Le nombre de parenthèses ouvrantes de x .
- $D(x) = |x|_r =$ Le nombre de parenthèses fermantes de x .

Ainsi, PAREN est le langage des mots x qui respectent les deux axiomes suivants :

- 1 $G(x) = D(x)$, et
- 2 Pour tout préfixe $y = x_1 \dots x_{k \leq |x|}$ de x , $G(y) \geq D(y)$.

Question : Montrer que PAREN \notin **Reg**.

Problème des parenthèses

La courbe ci-dessous permet d'appréhender intuitivement les propriétés de PAREN.



Figure – Fonction $G(y) - D(y)$ sur l'intervalle des préfixes de x

Un mot $x \in \text{PAREN}$ si et seulement si $G(x) - D(x) = 0$ et si, la courbe ne descend jamais en dessous de 0.

Exemples

Déterminer une grammaire non-contextuelle qui génère PAREN.

Problème des parenthèses

Soit grammaire G_{PAREN} suivante :

$$S \rightarrow [S] | SS | \varepsilon$$

On a $L(G_{\text{PAREN}}) = \text{PAREN}$.

Exemples

Vérifier que le mot représenté sur la figure précédente peut être généré par la grammaire G .

Grammaire des expressions arithmétiques

Soit grammaire G_{ARI} suivante :

$$E \rightarrow E + E \mid E - E \mid E \times E \mid (E) \mid a \mid b$$

Exemples

Donner la dérivation à gauche, puis à droite du mot $a + a \times a$.

Grammaire des expressions arithmétiques

Soit grammaire G_{ARI} suivante :

$$E \rightarrow E + E \mid E - E \mid E \times E \mid (E) \mid a \mid b$$

Exemples

Donner la dérivation à gauche, puis à droite du mot $a + a \times a$.

À gauche :

$$\begin{aligned} E &\Rightarrow E + E \\ &\Rightarrow a + E \\ &\Rightarrow a + E \times E \\ &\Rightarrow a + a \times E \\ &\Rightarrow a + a \times a \end{aligned}$$


À droite :

$$\begin{aligned} E &\Rightarrow E \times E \\ &\Rightarrow E \times a \\ &\Rightarrow E + E \times a \\ &\Rightarrow E + a \times a \\ &\Rightarrow a + a \times a \end{aligned}$$

Arbre de dérivation

Il est possible de représenter la dérivation sous forme arborescente.

$$\begin{aligned} E &\Rightarrow E + E \\ &\Rightarrow a + E \\ &\Rightarrow a + E \times E \\ &\Rightarrow a + a \times E \\ &\Rightarrow a + a \times a \end{aligned}$$



Définition

Soit $G = (V, \Sigma, P, S)$ une grammaire hors-contexte. Un arbre Δ est un *arbre de dérivation* pour G si et seulement si :



- 1 la racine de Δ est étiquetée par l'axiome S ;
- 2 chaque nœud interne est étiqueté par une variable dans V ;
- 3 chaque feuille est étiquetée par un symbole dans $V \cup \Sigma \cup \{\varepsilon\}$;
- 4 toute feuille étiquetée par ε est l'unique nœud de son parent ;
- 5 si un nœud interne est étiqueté par A , et tous ses nœuds fils (de gauche à droite) sont étiquetés par X_1, X_2, \dots, X_k , alors $\rightarrow X_1 X_2 X_k$ est une règle de production dans P .

Arbre de dérivation

Définition

La *frontière* $B(\Delta)$ est la chaîne formée de toutes les feuilles de gauche à droite d'un arbre de dérivation Δ (i.e. parcours préfixe des feuilles).

Exemples



Définition

Un arbre de dérivation Δ est dit *terminal* si $\forall x \in B(\Delta), x \in \Sigma$, i.e. tous les symboles de la frontière sont des symboles terminaux.

Corollaire

Soit une grammaire G et un arbre de dérivation terminal Δ_G issu de G , alors $B(\Delta_G) \in L(G)$.

Table of Contents

- 1 Grammaire formelle
- 2 Exemples de grammaire
 - Problème des parenthèses
 - Grammaire des expressions arithmétiques
- 3 Grammaires ambiguës

Définition

Soit $G = (V, \Sigma, P, S)$ une grammaire hors-contexte.

On dit que G est *ambiguë* si : $\exists \mathfrak{N} \in \Sigma^*$ et Δ_1, Δ_2 , deux arbres de dérivation terminaux tels que $\Delta_1 \neq \Delta_2$ et $B(\Delta_1) = B(\Delta_2) = \mathfrak{N}$.

Exemples

Montrer que la grammaire des expressions arithmétiques vue précédemment est une grammaire ambiguë.

Analyse de l'ambiguïté

- Généralement, l'ambiguïté provient de dérivations parallèles formant une même séquences de symboles non terminaux.
- Par exemple, dans la grammaire G_{ARI} , E produit $E + E$ ou $E \times$, et chacune permet d'arriver à la séquence $E + E \times E$.
- Afin d'éviter ce problème, et dans ce cas précis, il est possible d'utiliser une variable supplémentaire afin de différencier les termes des différents opérateurs.

Analyse de l'ambiguïté

- Généralement, l'ambiguïté provient de dérivations parallèles formant une même séquences de symboles non terminaux.
- Par exemple, dans la grammaire G_{ARI} , E produit $E + E$ ou $E \times$, et chacune permet d'arriver à la séquence $E + E \times E$.
- Afin d'éviter ce problème, et dans ce cas précis, il est possible d'utiliser une variable supplémentaire afin de différencier les termes des différents opérateurs.

On donne la nouvelle grammaire G_{ARI} suivante :

$$\begin{aligned} E &\rightarrow E + T \mid E - T \mid T \\ T &\rightarrow T \times F \mid F \\ F &\rightarrow (E) \mid a \mid b \end{aligned}$$

Exemples

Vérifier que cette grammaire ne provoque plus d'ambiguïté pour le mot $a + a \times a$.

Bien

- Il est parfois possible de lever manuellement l'ambiguïté d'une grammaire.
- Il existe des conditions suffisantes pour garantir la non-ambiguïté.

Suppression et détection de l'ambiguïté

Bien

- Il est parfois possible de lever manuellement l'ambiguïté d'une grammaire.
- Il existe des conditions suffisantes pour garantir la non-ambiguïté.

Moins bien...

- Il n'existe pas d'algorithme permettant de le faire de façon automatique.
- Le problème de savoir si une grammaire est ambiguë ou non est indécidable.
- Il existe des langages hors-contexte qui ne peuvent être générés que par des grammaires ambiguës.